

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 7 · Nível 2 — Análogo · Caminhões/comerciais · validação full-text 16/08/2026

1. Identificação

ID (master)	7
Arquivo	033-Air_Pressure_System_Failure_Prediction_and_Classification_in_Scania_Trucks_using_M.pdf
Título (EN)	Air Pressure System Failure Prediction and Classification in Scania Trucks using Machine Learning
Título (PT)	Predição e Classificação de Falhas do Sistema de Pressão de Ar em Caminhões Scania usando Aprendizado de Máquina
Autores	K Tamil Selvi; K Pratheeksha; N Praveena; S Ragunathan; R Thamilselvan (Kongu Engineering College, Erode, Tamil Nadu, Índia)
Veículo / Ano	2022 Second International Conference on Artificial Intelligence and Smart Energy (ICAIS-2022), IEEE, 2022
DOI	10.1109/ICAIS53314.2022.9742716
Palavras-chave	Air Pressure System; Convolution; Class Imbalance; Classification; Accuracy; Predictive Maintenance
Datas	Conferência ICAIS-2022; sem datas de submissão/aceite no texto

2. Resumo traduzido (PT)

O Sistema de Pressão de Ar (APS) é parte vital de veículos pesados como os caminhões Scania. O sistema de frenagem desses veículos depende da pressão de ar, daí a necessidade de funcionamento adequado do APS. A manutenção preditiva na indústria automotiva reduz o custo de manutenção e melhora o desempenho do veículo, o que pode ser feito de forma manual ou automática. A manutenção preditiva manual exige intervenção humana e pode induzir erros; a automática, via técnicas de inteligência artificial, explora a causa oculta das falhas do APS. No sistema proposto, abordagens de aprendizado de máquina são investigadas para manutenção preditiva com base na condição do APS. O conjunto de dados usado contém 59.000 instâncias negativas e 1.000 positivas, exigindo tratar o desbalanceamento de classes antes de aplicar os algoritmos. Várias técnicas de reamostragem (undersampling, oversampling e SMOTE) são analisadas quanto à eficiência do classificador. Após o pré-processamento, algoritmos de classificação (Random Forest, Regressão Logística, SVM, Naive Bayes, Árvore de Decisão, KNN e Gradiente Descendente Estocástico) são implementados e sua acurácia analisada. Os resultados experimentais mostram que o SGD com undersampling supera os demais classificadores, com acurácia de 99%.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Random Forest, Regressão Logística, SVM (kernel RBF), Naive Bayes, Árvore de Decisão, KNN, Gradiente Descendente Estocástico (SGD); reamostragem: undersampling (NearMiss/Random), oversampling (Random) e SMOTE (k=5)
Paradigma (SQ.3)	Supervisionado (classificação binária: positivo/negativo)
Ferramentas	Google Colaboratory; scikit-learn; imbalanced-learn/imblearn (NearMiss, RandomOverSampler, SMOTE)
Métricas (SQ.4/C4)	Acurácia, Precisão, Recall e F1-score
Dataset (C2)	APS Failure at Scania Trucks Data Set (UCI ML Repository); treino 60.000 (59.000 negativas / 1.000 positivas), teste 16.000 (375 positivas / 15.625 negativas); 171 atributos numéricos, nomes anonimizados
Validação (C3)	Split treino/teste pré-definido do UCI; SEM validação cruzada; reamostragem aplicada; protocolo de avaliação no conjunto de teste separado é ambíguo (tabelas reportam só 'antes/depois da reamostragem'), com risco de vazamento se o oversampling/SMOTE foi aplicado antes da separação treino/teste
Melhor modelo/resultado	Inconsistência interna: a conclusão aponta Random Forest (99% de acurácia com dados reamostrados), enquanto o abstract aponta SGD com undersampling (99%); LR, NB e KNN também atingem ~0,99

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios econômicos citados apenas qualitativamente (redução de custo de manutenção e
-----------------	---

	melhora de desempenho); o único benefício mensurável reportado é a acurácia de classificação (até 99%). Nenhuma cifra de economia, disponibilidade ou downtime evitado
SQ.5 Código	Não compartilhado — uso do Google Colab mencionado, mas sem link para repositório ou notebook público
SQ.6 Dados	Público — 'APS Failure at Scania Trucks Data Set' do UCI ML Repository (dataset amplamente conhecido e reutilizável)
SQ.7 Desafios	Forte desbalanceamento de classes (59:1) e risco de misclassificação da classe minoritária; perda de informação no undersampling; overfitting no oversampling; atributos anonimizados (171 numéricos sem semântica); dados reais ruidosos exigindo pré-processamento
SQ.8 Lacunas/futuro	Trabalho futuro: aplicar seleção avançada de atributos para identificar os que mais contribuem para a falha do APS e explorar causas ocultas de falhas recorrentes; induzir tecnologias avançadas para sistemas de freio a ar

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	Seções IV-V descrevem claramente os algoritmos (7 classificadores) e o pré-processamento (3 técnicas de reamostragem: NearMiss, RandomOverSampler, SMOTE k=5); parâmetros só parcialmente informados (SVM=RBF; demais em default, sem tuning). Mantido 1, com ressalva sobre hiperparâmetros
C2 Dados	1	1	Seção V.A dá origem e tamanho exatos (UCI; 60.000 treino, 16.000 teste, 171 atributos) e o desbalanceamento é tratado explicitamente por 3 técnicas. Confirmado 1
C3 Validação	1	0.5	Há conjunto de teste pré-definido (16.000), mas as tabelas reportam só 'antes/depois da reamostragem' sem deixar claro que a avaliação final ocorreu no teste retido; sem validação cruzada; métricas quase perfeitas (0,99-1,00) após reamostragem sugerem possível vazamento se o SMOTE/oversampling foi aplicado antes do split. Rebaixado de 1 para 0,5
C4 Métricas	0.5	0.5	Reporta acurácia, precisão, recall e F1, porém destaca a acurácia como métrica principal em problema altamente desbalanceado (inadequado) e omite a métrica de custo padrão do dataset APS (FN=500/FP=10), AUC-ROC e matriz de confusão. Mantido 0,5
C5 Impacto/frota	0.5	0.5	Aplicação prática declarada qualitativamente (manutenção de caminhões pesados). Transferibilidade a E&C plausível (freio a ar/APS de veículos pesados diesel é análogo a caminhões basculantes/fora-de-estrada de construção), mas sem quantificar nem discutir E&C. Mantido 0,5
C6 Reprodutib.	0	0.5	Dados públicos (UCI APS Scania) garantem reprodutibilidade parcial; código NÃO compartilhado. Como a rubrica exige código E dados, atende metade — elevado de 0 para 0,5

Total: 4.0 (Moderada) → 4.0 (Moderada).

Mudanças vs 1ª passagem: C3 rebaixado de 1 para 0,5 (protocolo de validação ambíguo, sem CV, risco de vazamento na reamostragem). C6 elevado de 0 para 0,5 (dataset UCI público, embora sem código). Total permanece 4,0 (topo da faixa Moderada) por compensação

6. Alerta de escopo / observações

Escopo: Domínio é caminhões pesados Scania (comerciais rodoviários), não E&C; dataset UCI genérico de caminhões. Coerente com Nível 2 — Análogo (APS/freio a ar transferível a frotas pesadas de E&C).

Observações: Frente à 1ª passagem, o full-text acrescenta LR, Naive Bayes e SGD, além de undersampling (NearMiss). Inconsistência interna entre abstract (melhor=SGD+undersampling) e conclusão (melhor=Random Forest). Uso de acurácia como métrica-chave em base 59:1 é fraco. Mismatch de citação do dataset ([18])