

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 11 · Nível 2 — Análogo · Caminhões/comerciais · validação full-text 16/08/2026

1. Identificação

ID (master)	11
Arquivo	11-Data-Driven_Methodology_for_Predictive_Maintenance_of_Commercial_Veh.pdf
Título (EN)	Data-Driven Methodology for Predictive Maintenance of Commercial Vehicle Turbochargers
Título (PT)	Metodologia orientada a dados para manutenção preditiva de turbocompressores de veículos comerciais
Autores	Tiago Nascimento de Freitas; Ricardo Gaspar; Rômulo Gonçalves Lins (UFABC, Brasil); Elmer John Hartman Junior (Scania Latin America Ltda., Brasil)
Veículo / Ano	2023 15th IEEE International Conference on Industry Applications (INDUSCON), 2023
DOI	10.1109/INDUSCON58041.2023.10374966
Palavras-chave	predictive maintenance; turbocharger; data mining; machine learning
Datas	Conferência INDUSCON 2023; PDF baixado do IEEE Xplore em 21/07/2026

2. Resumo traduzido (PT)

A manutenção preditiva desempenha papel importante para garantir a lucratividade de empresas que dependem de veículos comerciais como ativo durável central no transporte. Contudo, desenvolver modelos preditivos precisos e confiáveis para tais equipamentos exige metodologias específicas de análise de dados. Este trabalho propõe uma metodologia orientada a dados (data-driven) para manutenção preditiva de veículos comerciais, composta por três etapas principais adaptadas de métodos genéricos de mineração de dados: Entendimento do Problema, Entendimento dos Dados e Preparação dos Dados. Utilizou-se um estudo de caso baseado em dados operacionais e no histórico de manutenção de turbocompressores para demonstrar a viabilidade da metodologia, que se baseia na coleta e análise de dados reais da indústria para a análise detalhada de variáveis relevantes e a preparação do conjunto de dados para a construção de um modelo preditivo. Assim, é possível identificar tendências e padrões que permitam prever possíveis falhas antes que ocorram, aumentando a disponibilidade (uptime) e reduzindo custos de manutenção.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Mineração de dados / CRISP-DM adaptado a 3 fases (Problem/Data Understanding, Data Preparation). Abordagem PROPOSTA: Sliding-Box (classificação binária falha/não-falha, horizonte 90 dias). Pré-processamento: descarte de variáveis com >65% de nulos, imputação pela média, balanceamento por SMOTE, normalização MinMaxScaler, agrupamento por faixas de 5000 km com forward-fill. IMPORTANTE: nenhum algoritmo de ML preditivo foi treinado — escopo exclui explicitamente o desenvolvimento de modelos
Paradigma (SQ.3)	Supervisionado (classificação binária proposta via Sliding-Box), mas modelo NÃO implementado — trabalho de preparação de dados
Ferramentas	Python (NumPy, Pandas, Matplotlib); scikit-learn (MinMaxScaler); imbalanced-learn (SMOTE); SQL; DBeaver
Métricas (SQ.4/C4)	Nenhuma métrica de desempenho preditivo (sem modelo treinado). Apenas estatísticas descritivas: % de nulos por feature, distribuição de classes (16% positiva) antes/depois do SMOTE, matriz de correlação
Dataset (C2)	Dados reais da indústria (Scania), repositório central; caminhões Euro V, fab. 2018; mercados europeu e sul-americano. 95 veículos com falha de turbo + 100 sem falha (195 no total); 3 fontes (TSD, OD, MD); 38 variáveis; matriz 7496×1031 → 7496×735 após preparação; classe positiva 16% tratada com SMOTE. Dados anonimizados (LGPD)
Validação (C3)	Sem validação de modelo (modelo não construído). Elementos parciais: imputação pela média ajustada no treino (anti-vazamento) e rotulagem temporal por janela de 90 dias. Sem CV, sem teste avaliado, sem split temporal; SMOTE/normalização descritos sem separação por fold (risco latente de vazamento)
Melhor modelo/resultado	N/A — nenhum modelo treinado; escopo limitado à preparação de dados

4. Questões secundárias (evidência)

SQ.1 Benefícios	Sem benefícios quantificados. Apenas expectativas qualitativas: aumento de uptime, redução de custos/downtime, apoio à decisão de oficinas/operadores de frota. Números existentes referem-se ao dataset, não a ganhos de negócio
SQ.5 Código	Não compartilhado (bibliotecas nomeadas, sem link)
SQ.6 Dados	Não — dados proprietários/confidenciais da Scania; anonimizados conforme LGPD
SQ.7 Desafios	Dados não coletados para PdM; formato não estruturado; coleta em intervalos irregulares; grande volume de nulos; desbalanceamento (16%); alta correlação entre features; heterogeneidade de configurações/mercados; turbo sem sensores diretos de condição; necessidade de cooperação engenharia+TI
SQ.8 Lacunas/futuro	Explorar fontes de dados adicionais; incorporar modelagem mais avançada; desenvolver metodologia de coleta/armazenamento estruturado para PdM. Lacuna central: o modelo preditivo em si fica como trabalho futuro (este artigo só preparou o dataset)

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	Metodologia de preparação descrita com rigor (§III-D, IV-C): técnicas nomeadas com biblioteca e parâmetros (descarte >65% nulos, Mean Imputation no treino, SMOTE, MinMaxScaler 0-1, binning 5000 km, horizonte 90 dias). Ressalva: nenhum algoritmo preditivo é treinado, mas o método do que foi feito é claro
C2 Dados	0.5	1	AJUSTE PARA CIMA. Full-text caracteriza o dataset de forma completa (§IV-A/B): origem (Scania, Euro V 2018, EU/AmSul), tamanho (195 veículos; 7496×1031→735; 38 variáveis) E trata desbalanceamento (16%, SMOTE). Justifica 1,0 em vez de 0,5
C3 Validação	0.5	0.5	Confirmado (parcial). Sem validação de modelo (não treina). Créditos por MI ajustada no treino e rotulagem temporal (90 dias); mas sem CV, sem teste avaliado e SMOTE/normalização sem separação por fold (risco latente). Mantido 0,5
C4 Métricas	0	0	Confirmado. Nenhuma métrica de desempenho preditivo (sem modelo). Resultados são só estatísticas descritivas de preparação. Score 0,0
C5 Impacto/frota	0.5	0.5	Relevância prática clara para frota (uptime/custos, Sliding-Box para decisão de oficina) e conclusão discute transferibilidade a outros bancos/componentes. Menção a caminhões de mineração/haulage aproxima do universo E&C, mas impacto qualitativo/potencial (sem modelo, sem números). Mantido 0,5
C6 Reprodutib.	0	0	Sem reprodutibilidade: dados confidenciais (LGPD) e sem código/repositório. Score 0,0

Total: 2.5 (Moderada) → 3.0 (Moderada).

Mudanças vs 1ª passagem: Única alteração: C2 sobe de 0,5 para 1,0 (full-text caracteriza tamanho/origem e trata desbalanceamento com SMOTE). C1, C3, C4, C5, C6 confirmados. Total 2,5 → 3,0 (mantém faixa Moderada)

6. Alerta de escopo / observações

Escopo: Artigo declara EXPLICITAMENTE que o escopo NÃO inclui desenvolvimento de modelo preditivo nem sistema de diagnóstico — é artigo de PREPARAÇÃO DE DADOS (3 primeiras fases do CRISP-DM), sem modelo, sem métricas, sem avaliação preditiva. Estudo NÃO fornece evidência de desempenho de IA. Domínio = caminhões comerciais (transporte), coerente com Nível 2 Análogo; menção a mineração/haulage reforça a analogia a E&C

Observações: Estudo de caso com dados reais Scania (turbo sem sensor direto; usa TSD+OD+MD). Forte seção de trabalhos relacionados sobre PdM em veículos pesados (útil p/ snowballing). Útil p/ SQ7 (desafios de dados industriais) e SQ8, mas baixo valor p/ MQR/SQ3/SQ4 por não treinar modelo nem reportar métricas.