

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 19 · Nível 2 — Análogo · Empilhadeiras · validação full-text 16/08/2026

1. Identificação

ID (master)	19
Arquivo	004-Hybrid_Physics-Inspired_Machine_Learning_Framework_for_Predictive_Maintenance.pdf
Título (EN)	Hybrid Physics-Inspired Machine Learning Framework for Predictive Maintenance of Forklift Chains: Leveraging Sensor Data Characteristics
Título (PT)	Estrutura híbrida de aprendizado de máquina inspirada na física para manutenção preditiva de correntes de empilhadeiras: aproveitando as características dos dados de sensores
Autores	Osman Akcatepe; Michael Moeckel (University of Applied Sciences Aschaffenburg, Alemanha)
Veículo / Ano	2023 11th International Conference on Control, Mechatronics and Automation (ICCMA), IEEE, 2023
DOI	10.1109/ICCMA59762.2023.10375057
Palavras-chave	Physics-inspired machine learning; Feature engineering; Data-driven modeling; Forklifts; Predictive Maintenance; Remaining Useful Life (RUL); Industry 4.0
Datas	Conferência 2023; baixado do IEEE Xplore em 01/02/2026

2. Resumo traduzido (PT)

Preencher a lacuna entre a modelagem baseada em física e o aprendizado de máquina orientado a dados promete reduzir a quantidade de dados de treinamento necessária e melhorar a explicabilidade em aplicações de manutenção preditiva. Para uma pequena frota de empilhadeiras industriais, os autores desenvolvem uma estrutura fisicamente inspirada para prever a vida útil remanescente (RUL) de componentes selecionados, integrando extração de atributos fisicamente motivada, modelagem de degradação e aprendizado de máquina. A abordagem é promissora para situações de disponibilidade limitada de dados ou grande heterogeneidade, frequentes em frotas de veículos customizados otimizados para tarefas específicas.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Hybrid Physics-Inspired ML (hPIML) com extração automatizada de atributos; Random Forest (regressão) como estimador dos parâmetros do modelo de degradação; comparado a PINN (PINN-AFE) e a abordagem puramente data-driven (DD-SFE); modelo de degradação físico (exponencial + polinomial de 2ª ordem); feature engineering físico (energia potencial, torque, momento, hidráulica) + atributos estatísticos; predição de RUL
Paradigma (SQ.3)	Supervisionado (regressão para RUL; rótulos derivados de relatórios de serviço/troca de componentes)
Ferramentas	Não especifica bibliotecas de implementação; cita NVIDIA Modulus só como exemplo de toolkit PIML na introdução (não confirmado como usado); scripts de extração de atributos; Random Forest
Métricas (SQ.4/C4)	RMSE, MAE e R2-score (Tabela 1)
Dataset (C2)	Pequena frota de empilhadeiras industriais (dados da Linde Material Handling); séries temporais multivariadas (velocidade de tração/motor, altura de elevação, carga, ângulo do mastro, aceleração 3D, deflexão do joystick, horas de operação); rótulo de RUL de relatórios de serviço; pré-processamento com limpeza e downsampling; volume só descrito como 'pequeno' — sem quantificação de veículos, amostras ou falhas
Validação (C3)	Hold-out 70% treino / 15% validação / 15% teste; benchmarking das três abordagens no teste; sem CV e sem split temporal; risco de vazamento (segmentos da mesma série/veículo em treino e teste) não discutido, agravado pelo dataset muito pequeno
Melhor modelo/resultado	hPIML (Random Forest): RMSE=13,45; MAE=18,92; R2=0,789 — supera PINN-AFE (RMSE=21,78; R2=0,612) e DD-SFE (RMSE=15,25; R2=0,755)

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios mensuráveis limitados a métricas de modelo (hPIML R2=0,789). Benefícios operacionais (redução de downtime, confiabilidade, menor necessidade de dados de treino) apenas qualitativos, sem quantificação
-----------------	--

SQ.5 Código	Não há compartilhamento de código; nenhum repositório; a própria equação do modelo de degradação não é apresentada
SQ.6 Dados	Dados proprietários da Linde Material Handling; acesso limitado; não públicos
SQ.7 Desafios	Disponibilidade limitada de dados; alta heterogeneidade de frotas customizadas; dados de sensores ruidosos exigindo limiares finetuned; risco de overfitting em dataset pequeno; alongação da corrente não mensurável de forma contínua; predição de RUL no regime de poucos dados
SQ.8 Lacunas/futuro	Validar em dataset maior; substituir a função-objetivo de degradação (fenomenológica) por modelos físicos mais detalhados; conclusões preliminares ('first test implementation'); estender abordagens PIML

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	0.5	§III-IV descrevem o pipeline (RF, PINN, DD; pré-proc.: limpeza, downsampling, feature engineering; família do modelo de degradação). Porém a dimensão 'parâmetros' é deficiente: RF usado 'for simplicity' sem hiperparâmetros; arquitetura da rede (PINN) não especificada; equação do modelo de degradação ausente; limiares 'finetuned' não informados; bibliotecas não citadas. É 'first test implementation' — não reproduzível nos parâmetros. Rebaixado 1→0,5
C2 Dados	0.5	0.5	§II.B descreve bem a origem (Linde, dados genuínos) e a natureza multivariada, mas o tamanho é só qualitativo ('small fleet'), sem número de veículos/amostras/falhas. Regressão (RUL) → desbalanceamento N/A, mas a escassez de dados/falhas é só qualitativa. Confirma 0,5
C3 Validação	0.5	0.5	§IV.A explicita hold-out 70/15/15 com teste separado e benchmarking (crédito). Sem CV, sem split temporal e sem discussão de vazamento (relevante em séries temporais de frota com dataset mínimo). Confirma 0,5
C4 Métricas	0	1	Abstract não traz métricas, mas o full-text (§IV.D-G e Tabela 1) reporta RMSE, MAE e R2 para as três abordagens — métricas adequadas p/ RUL/regressão. Upgrade 0→1 (a anomalia MAE>RMSE é registrada em observações como problema de reporte, não de adequação da métrica)
C5 Impacto/frota	0.5	0.5	Impacto prático claro: foco na corrente de carga (peça de desgaste cara), com objetivo de reduzir downtime; dados industriais reais. Transferibilidade a E&C plausível (empilhadeiras compartilham heterogeneidade/escassez de falhas com equipamentos pesados de E&C). Contudo, resultados preliminares e impacto não quantificado. Confirma 0,5
C6 Reprodutib.	0	0	§II.B e Agradecimentos deixam claro que os dados são proprietários (acesso limitado) e não públicos; nenhum código; equação sequer apresentada. Confirma 0

Total: 2.5 (Moderada) → 3.0 (Moderada).

Mudanças vs 1ª passagem: Duas mudanças: (1) C1 1→0,5 (ausência de hiperparâmetros do RF, arquitetura da rede não especificada, equação do modelo ausente; primeira implementação de teste); (2) C4 0→1 (Tabela 1 traz RMSE/MAE/R2, invisíveis no abstract). Efeito líquido: 2,5 → 3,0. C2, C3, C5, C6 confirmados

6. Alerta de escopo / observações

Escopo: Frota de empilhadeiras industriais (intralogística), coerente com Nível 2 — Análogo, não E&C direto. Ressalva de qualidade (não de escopo): evidência preliminar — 'first test' em dataset muito pequeno, N não quantificado, os próprios autores dizem ser cedo para conclusões

Observações: Inconsistência na Tabela 1: para o hPIML, $MAE=18,92 > RMSE=13,45$, matematicamente impossível para o mesmo conjunto — provável erro de reporte; citar com cautela. Artigo curto (4 páginas). Financiamento: projeto KANIS (Baviera). hPIML é a contribuição central; PINN e DD-SFE são baselines