

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 25 · Nível 2 — Análogo · Ferroviário/Metrô · validação full-text 16/08/2026

1. Identificação

ID (master)	25
Arquivo	25-Predictive_Maintenance_of_Urban_Metro_Vehicles_Classification_of_Fai.pdf
Título (EN)	Predictive Maintenance of Urban Metro Vehicles: Classification of Failures Using Machine Learning
Título (PT)	Manutenção Preditiva de Veículos de Metrô Urbano: Classificação de Falhas Usando Aprendizado de Máquina
Autores	Ayat A. Najjar; Huthaifa I. Ashqar; Ahmad Hasasneh (Arab American University, Ramallah, Palestina)
Veículo / Ano	2025 IEEE 4th International Conference on Computing and Machine Intelligence (ICMI), 2025
DOI	10.1109/ICMI65310.2025.11141125
Palavras-chave	Air Production Unit; Failure Detection; Fleet Management; Machine Learning; Metro; Predictive Maintenance
Datas	Conferência 2025; dataset coletado jan-jun/2022; baixado do IEEE Xplore (USP) em 21/07/2026

2. Resumo traduzido (PT)

A manutenção preditiva (PdM) é crucial para que empresas evitem paradas não planejadas, aumentem a confiabilidade global e reduzam custos operacionais. A detecção e classificação de falhas é elemento-chave da PdM. Neste estudo propõe-se um framework de aprendizado de máquina para identificar em tempo real falhas na Unidade de Produção de Ar (APU) de veículos de metrô, com potencial para gerar um sistema de recomendação para falhas da APU. Propôs-se uma classificação binária utilizável em tempo real para informar imediatamente os operadores sobre possível falha futura, e um algoritmo de multiclassificação capaz de identificar o tipo exato da falha. O framework apresentou F1-score de ~85% para o classificador binário e 97% para a multiclassificação usando Random Forest sobre o dataset MetroPT. Constatou-se que os sensores analógicos foram mais discriminantes que os digitais; a pressão dos tanques de ar, a temperatura do óleo no compressor e os valores do fluxômetro mostraram-se altamente importantes. Ao prever quando a manutenção é necessária, os operadores podem tratar problemas de segurança antes que se agravem, melhorar a confiabilidade e reduzir interrupções aos passageiros. O framework é aplicável em campo e apoia decisões de reparar ou substituir ativos.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Random Forest para classificação binária (falha/não-falha) e multiclasse (4 classes: sem falha, vazamento de ar em clientes, vazamento no secador, vazamento de óleo no compressor); seleção de atributos por importância (feature importance do RF)
Paradigma (SQ.3)	Supervisionado
Ferramentas	Não declaradas explicitamente; uso de Label Encoder e RF sugere scikit-learn/Python, mas o texto não nomeia bibliotecas nem versões
Métricas (SQ.4/C4)	Acurácia, Precisão, Recall e F1-Score (por classe, antes e depois do balanceamento); evitaram acurácia isolada por causa do desbalanceamento
Dataset (C2)	MetroPT (Metro do Porto) — 10.979.547 registros sem valores ausentes, 21 atributos de sensores analógicos e digitais + GPS; trem ativo com ~26 viagens/dia entre jan e jun/2022; 3 falhas rotuladas por logs de manutenção; altamente desbalanceado, tratado por undersampling; público via Zenodo
Validação (C3)	Holdout treino:teste 67:33; sem validação cruzada; sem split temporal (timestamp removido, sob argumento de que a falha não se liga a data/hora); undersampling aplicado. Risco de vazamento: split aleatório sobre série temporal de amostras contíguas correlacionadas pode inflar as métricas
Melhor modelo/resultado	Random Forest — binário: acurácia ~84%, F1 ~0,83-0,85; multiclasse: acurácia ~87%, F1 de 0,73 (classe 0) a 0,97 (classes 1 e 2), 0,81 (classe 3)

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios mensuráveis são apenas as métricas de modelo (F1 ~85% binário; até 97% multiclasse). Benefícios operacionais (custos, downtime, confiabilidade, segurança) apenas qualitativos, sem
-----------------	--

	quantificação
SQ.5 Código	Não compartilhado. Sem repositório ou material suplementar
SQ.6 Dados	Dados públicos. MetroPT disponível via Zenodo (ref. [10]) e descrito em Scientific Data (ref. [9])
SQ.7 Desafios	(1) Disponibilidade e qualidade de dados históricos (incompletos, ruidosos, desbalanceados); (2) equilíbrio entre falsos positivos (manutenção desnecessária) e falsos negativos (falhas não detectadas), ajuste dependente do context
SQ.8 Lacunas/futuro	Lacunas endereçadas: falta de especificidade na detecção, capacidades insuficientes em tempo real e pouco detalhamento na classificação de falhas em metrô. Direção futura: evoluir para sistema de recomendação de manutenção da APU em tempo real; sem discussão de generalização a outras frotas/domínios

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	0.5	§II-C: RF claramente definido e §II-B: pré-processamento bem descrito (timestamp→DateTime, Label Encoder, split 67:33, undersampling) + seleção por importância. Porém NÃO há relato de hiperparâmetros do RF nem de tuning. Dois dos três componentes plenos; parâmetros ausentes. Rebaixado 1→0,5
C2 Dados	1	1	§II-A: origem e tamanho muito bem especificados (MetroPT, 10.979.547 registros, 21 atributos, jan-jun/2022). Desbalanceamento reconhecido e tratado por undersampling. Confirmado 1
C3 Validação	1	0.5	Existe teste separado (holdout 67:33) — mínimo atendido. Mas sem CV; sem split temporal (timestamp removido); risco de vazamento por split aleatório em série temporal correlacionada + undersampling, que tende a inflar F1/acurácia. Rebaixado 1→0,5
C4 Métricas	1	1	§III e Tabelas II-III: métricas adequadas — Acurácia, Precisão, Recall e F1 por classe, com justificativa de não confiar na acurácia isolada. Adequado. Confirmado 1
C5 Impacto/frota	0.5	0.5	Aplicação prática clara (alertas em tempo real, base para sistema de recomendação), mas benefícios operacionais qualitativos. Transferibilidade a E&C não discutida (domínio metrô); como Análogo, ganho plausível (frota, sensores de pressão/temperatura/vibração). Mantém 0,5
C6 Reprodutib.	0.5	0.5	Reprodutibilidade parcial: DADOS públicos (MetroPT/Zenodo) porém CÓDIGO não disponibilizado e hiperparâmetros não reportados. Rubrica exige código E dados; só dados. Mantém 0,5

Total: 5.0 (Alta) → 4.0 (Moderada).

Mudanças vs 1ª passagem: Duas reduções após a leitura do texto completo, com critério mais rigoroso. C1 1→0,5 (sem hiperparâmetros nem tuning). C3 1→0,5 (só holdout, sem CV, sem split temporal, risco de vazamento). Total cai de 5,0 (Alta) para 4,0 (Moderada). C2, C4, C5, C6 confirmados

6. Alerta de escopo / observações

Escopo: PdM + ML supervisionado em fleet management de veículos (metrô), coerente com Nível 2 — Análogo. Ressalva: domínio ferroviário/metrô (Metro do Porto), não E&C.

Observações: Componente-alvo: APU (o texto oscila entre Air Production Unit e Auxiliary Power Unit). Sensores analógicos (TP2/TP3, reservatórios, temperatura do óleo, fluxômetro) mais discriminantes que digitais. Pequenas inconsistências entre resumo (F1 97%) e conclusão (acurácia 84%/87%). Duas etapas: binário (alerta) + multiclasse (tipo de falha).