

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 54 · Nível 2 — Análogo · Mineração · validação full-text 16/08/2026

1. Identificação

ID (master)	54
Arquivo	54-Predictive asset availability optimization for underground trucks and loaders in the mining industry.pdf
Título (EN)	Predictive asset availability optimization for underground trucks and loaders in the mining industry
Título (PT)	Otimização preditiva da disponibilidade de ativos para caminhões e carregadeiras subterrâneas na indústria de mineração
Autores	Sunil D. Patil; Abhishek Mitra; Krishnaveni Tuggali Katarikonda; Jan-Douwe Wansink (IBM India; Sandvik Mining and Rock Technology, Suécia)
Veículo / Ano	OPSEARCH (Journal of the Operational Research Society of India, Springer), vol. 58, pp. 751-772, 2021
DOI	10.1007/s12597-020-00502-4
Palavras-chave	Predictive asset availability optimization (PAAO); Predictive maintenance; Mining; Industry 4.0; Machine learning; CHAID; RUL; Feature engineering
Datas	Aceito 14/12/2020; online 28/01/2021

2. Resumo traduzido (PT)

Com o aumento do foco em otimização operacional, racionalização de custos e os avanços em sensores, armazenamento e ML, os OEMs de mineração precisam de máquinas inteligentes para criar vantagem competitiva. A Sandvik e a IBM desenvolveram um serviço customizado de gestão de frota e manutenção preditiva para os equipamentos de mineração da Sandvik, visando melhorar a Eficiência Global do Equipamento (OEE). O artigo discute a aplicação de analytics para reduzir o tempo de parada prevendo antecipadamente as falhas, melhorando a utilização dos ativos da frota. Detalha a jornada da análise usando dados de IoT, exploração de dados, aproximações estatísticas, diversos algoritmos de ML considerados e a seleção final das técnicas com base em critérios da indústria. Foram construídos modelos preditivos para falhas de componentes (motor, freios, transmissão) e modelos de tempo até a falha para caminhões e carregadeiras subterrâneas. Os modelos (com o IBM Predictive Analytics) foram integrados ao OptiMine Analytics da Sandvik. O trabalho destaca impacto financeiro significativo e depoimentos de clientes.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Árvores de decisão para classificação de falha de componente (CHAID, C5.0, C&R trees); modelo de riscos proporcionais de Cox customizado para eventos repetitivos (análise de sobrevivência) para tempo até a falha/RUL; engenharia de atributos com sensores virtuais; aprendizado sensível a custo (cost-sensitive); definição de alvo por zona de falha e variáveis de lag
Paradigma (SQ.3)	Supervisionado (classificação + análise de sobrevivência supervisionada)
Ferramentas	IBM SPSS Modeler v18.0; R v3.2; IBM Predictive Maintenance and Quality (PMQ); IBM Cloud; Sandvik OptiMine Analytics; CRISP-DM
Métricas (SQ.4/C4)	Classificação: Precisão, Recall e Taxa de Falsos Positivos (FPR) por componente e modelo com/sem feature engineering (Tabela 2). Cox: teste da hipótese de riscos proporcionais, teste de Grønnesby-Borgan, AIC (stepwise)
Dataset (C2)	~1 ano de dados de sensores a cada 5s de caminhões e carregadeiras subterrâneas Sandvik + histórico de falhas de motor/freios/transmissão; falhas <1% (fortemente desbalanceado); dezenas de tags de sensores. NÃO reporta N absoluto de registros nem nº de máquinas
Validação (C3)	Três esquemas de particionamento testados: aleatório, validação cruzada k-fold e particionamento temporal (time-based); amostra de teste separada (sobreajuste do C5.0 detectado em teste/CV). Variáveis de lag para prever um turno antes da zona de falha (mitiga vazamento temporal). Cox validado por hipótese PH, aderência e resíduos
Melhor modelo/resultado	CHAID com feature engineering (estável e interpretável, escolhido p/ produção). Motor de caminhão c/ FE em teste: precisão 80%, recall 82%, FPR 0,001% (vs 19%/60%/3% sem FE). Cox PH customizado p/ eventos repetitivos

4. Questões secundárias (evidência)

SQ.1 Benefícios	Aumento de 9% na OEE (mina de 30% de OEE; capacidade 3 Mt/ano → ganho de 0,08 Mt/ano), potencial de +USD 2,9 milhões/ano de receita; prevenção de múltiplas falhas maiores de componentes; ganho de ~22% na força do modelo e lift de 60% em precisão com feature engineering
SQ.5 Código	Não compartilhado. Solução proprietária (IBM SPSS/PMQ); sem repositório público
SQ.6 Dados	Não compartilhado. Dados proprietários de sensores/manutenção da Sandvik; não públicos
SQ.7 Desafios	<1% de falhas (fortemente desbalanceado), agravado por problemas de captura/registo; necessidade de sensores virtuais/feature engineering; exigência de modelos interpretáveis; modelagem de RUL com eventos repetitivos (Cox padrão não aplicável; baixo nº de falhas inviabilizou estratificação); sobreajuste do C5.0
SQ.8 Lacunas/futuro	Base para soluções prescritivas; extensível a engenharia e manufatura; literatura prévia carecia de estudo específico de falha de motor/freios/transmissão em caminhões/carregadeiras subterrâneos; horizontes muito curtos (1-3 min) em trabalhos anteriores; falta de implementações reais end-to-end em larga escala

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	Método muito bem detalhado: CRISP-DM, algoritmos nomeados (CHAID/C5.0/C&R e Cox PH customizado), pré-processamento explícito, 12 atributos derivados (Tabela 1), seleção stepwise por AIC no Cox, ferramentas com versões. Confirma 1
C2 Dados	0.5	0.5	Origem clara (sensores a cada 5s por ~1 ano + histórico) e tratamento de desbalanceamento exemplar (<1% de falhas, discussão crítica de SMOTE/undersampling/cost-sensitive, adoção de zona de falha + cost-sensitive). Porém o tamanho absoluto do dataset (N, nº de máquinas) não é reportado. Mantém 0,5
C3 Validação	0.5	1	§4.5: três esquemas (aleatório, CV k-fold, temporal), amostra de teste separada e detecção explícita de sobreajuste do C5.0. Variáveis de lag mitigam vazamento temporal; Cox validado. Robusta — sobe 0,5→1
C4 Métricas	0	1	§4.5 e Tabela 2 reportam Precisão, Recall e FPR por componente e modelo — adequadas para problema raro/desbalanceado. Cox por teste PH, aderência e AIC. Sobe 0→1
C5 Impacto/frota	1	1	Implantação real (IBM PMQ na nuvem, dashboards), impacto medido (+9% OEE, +USD 2,9 mi/ano) e testemunhos. Transferibilidade alta: frota de equipamento pesado móvel; a Sandvik atende mineração E construção; conclusão afirma extensibilidade a engenharia/manufatura. Confirma 1
C6 Reprodutib.	0	0	Sem código e sem dados públicos (Sandvik/IBM, plataforma comercial). Confirma 0

Total: 3.0 (Moderada) → 4.5 (Alta).

Mudanças vs 1ª passagem: Duas divergências para cima: C3 0,5→1 (CV k-fold + teste separado + particionamento temporal, §4.5, com detecção de sobreajuste) e C4 0→1 (Precisão/Recall/FPR na Tabela 2, adequadas ao desbalanceamento; testes estatísticos p/ o Cox). C1, C5, C6 confirmados; C2 mantido 0,5 (desbalanceamento excelente, mas tamanho absoluto ausente). Total 3,0→4,5; Moderada→Alta

6. Alerta de escopo / observações

Escopo: Mineração (caminhões/carregadeiras subterrâneos) confirma Nível 2 — Análogo. Analogia a E&C reforçada: Sandvik atende mineração e construção; alvo é frota de equipamento pesado móvel com PdM via IoT; autores declaram extensibilidade a engenharia/manufatura

Observações: Estudo industrial (IBM+Sandvik) de alta maturidade, deployment real e ganhos financeiros auditáveis — forte p/ SQ.1. Fraqueza central: reprodutibilidade ($C6=0$) e não quantificação do N (segura C2 em 0,5). Excelente p/ SQ.3, SQ.4 e SQ.7. Melhor modelo de classificação = CHAID com FE; há ainda modelo Cox PH para tempo até a falha.