

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 61 · Nível 2 — Análogo · Veículos pesados/comerciais (freios – APS) · validação full-text 21/09/2026

1. Identificação

ID (master)	61
Arquivo	61-Unveiling Brake Faults in Heavy Vehicles with Explainable AI.pdf
Título (EN)	Unveiling Brake Faults in Heavy Vehicles with Explainable AI
Título (PT)	Revelando falhas de freio em veículos pesados com IA explicável
Autores	Muhammad Ahmad Khan; Maqbool Khan; Sohail Khan; Asim Farooq; Wei Li; Zeeshan Ahmad; Faizan Ahmad
Veículo / Ano	Proceedings of Data Analytics and Management: ICDAM 2024, v. 2 (Lecture Notes in Networks and Systems, 1298). Singapore: Springer Nature Singapore, 2025. Conferência realizada na London Metropolitan University, Londres, jun. 2024.
DOI	10.1007/978-981-96-3355-5_43
Palavras-chave	Deteção de falhas de freio; IA explicável (SHAP); Random Forest; Manutenção preditiva; Veículos pesados; Sistema de pressão de ar (APS)
Datas	Conferência jun/2024; publicação 2025

2. Resumo traduzido (PT)

A detecção e o diagnóstico de falhas em freios são críticos para a segurança veicular; falhas não detectadas a tempo levam a desgaste de componentes e à falha do veículo, com risco à vida e perdas de tempo e recursos. Enfatizando a manutenção proativa, o estudo desenvolve um método para identificar problemas específicos dos componentes de freio pneumático (air brake) de veículos pesados. Com acurácia de classificação de 99,4%, o Random Forest (RF) superou os demais algoritmos avaliados. Modelos "caixa-preta" foram tornados interpretáveis via SHAP (SHapley Additive Explanations), que revelou 20 atributos determinantes; a aplicação sequencial do RF com esses 20 atributos manteve acurácia comparável, reduzindo complexidade e custo computacional.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Random Forest (modelo principal), comparado a Decision Tree, Gradient Boosting, Logistic Regression, K-NN, XGBoost e CatBoost; SHAP (Tree SHAP) para explicabilidade (XAI) e seleção de 20 atributos.
Paradigma (SQ.3)	Supervisionado — classificação binária (falha / não-falha do sistema de freio).
Ferramentas	Não especifica bibliotecas de implementação (implícito ecossistema Python/scikit-learn + SHAP).
Métricas (SQ.4/C4)	Apenas ACURÁCIA (Tabela 1: RF 0,99; DT 0,97; GB 0,97; LR 0,58...), reportada sob SMOTE/MICE/PCA. Não reporta F1, revocação, precisão ou AUC — problema é desbalanceado.
Dataset (C2)	Scania Trucks APS (Air Pressure System) Failure Data Set — UCI ML Repository (DOI 10.24432/C51S51). Dados reais, com valores ausentes e classes desbalanceadas; imputação por K-NN e balanceamento com SMOTE + Tomek Links.
Validação (C3)	Divisão treino/teste (holdout); SEM validação cruzada; ordem de aplicação do SMOTE não explicitada → risco de vazamento (data leakage).
Melhor modelo/resultado	Random Forest — acurácia 0,994 (99,4%). Com 20 atributos selecionados via SHAP, acurácia comparável,

	com menor complexidade computacional.
--	---------------------------------------

4. Questões secundárias (evidência)

SQ.1 Benefícios	Manutenção proativa de freios; ganho de segurança; redução de paradas/custos; menor complexidade computacional via seleção de atributos (SHAP).
SQ.5 Código	Não há compartilhamento de código nem repositório.
SQ.6 Dados	Dataset público (UCI APS Scania, com DOI) — dados disponíveis; código não disponibilizado.
SQ.7 Desafios	Valores ausentes; forte desbalanceamento de classes; opacidade de modelos "caixa-preta" (tratada com SHAP).
SQ.8 Lacunas/future	Aplicar Deep LIFT e LIME para ampliar a explicabilidade (proposto pelos autores). [Implícito: uso de métricas além da acurácia e validação mais robusta.]

5. Qualidade C1–C6 — 1ª passagem (resumo) × full-text (adotado pelo revisor em 21/09/2026)

Crit.	Resumo (1ª)	Full-text (proposta)	Justificativa (full-text)
C1 Método	0,5	0,5	Fluxo (Fig. 2), pré-processamento (K-NN, SMOTE-Tomek, MICE, PCA), modelos e SHAP descritos; faltam hiperparâmetros do RF e a razão do split (mesma lacuna do ID19). Mantém.
C2 Dados	0,5	1	Scania APS (UCI): real, público, com missing e desbalanceamento tratados (K-NN + SMOTE-Tomek). Mesmo dataset do ID7 (C2=1). ↑
C3 Validação	1	0,5	Apenas holdout treino/teste; sem validação cruzada; SMOTE sem ordem clara → risco de vazamento. Alinha ao ID7 (0,5). ↓ (resumo estava otimista)
C4 Métricas	0,5	0	Só acurácia (Tab. 1) em problema desbalanceado; a rubrica pede F1/AUC/revocação. ↓ (revisor pode manter 0,5 se quiser alinhar ao ID7)
C5 Relevância	0,5	0,5	Análogo pertinente (freios de veículos pesados/comerciais); não é E&C direto. Mantém.
C6 Reprodutib.	0	0,5	Dataset público (UCI, com DOI) permite replicação parcial; sem código/repositório. ↑

Total: 3,0 (Moderada) → 3,0 (Moderada). Aplicado na rubrica, planilha de qualidade e Apêndice B (medias por critério: C3 0,64->0,61; C4 0,59->0,57; C6 0,20->0,23; media global 3,70 e distribuicao inalteradas). Os ajustes se compensam (C2 ↑0,5 e C6 ↑0,5 vs C3 ↓0,5 e C4 ↓0,5) — a média global (3,70) e a distribuição (6 Alta / 14 Moderada / 2 Baixa) NÃO mudam.

6. Alerta de escopo / observações

Escopo: Nível 2 — Freios pneumáticos de veículos pesados/comerciais (HCRVs); pertinente à manutenção preditiva de frotas, porém NÃO é estudo direto do setor de Engenharia e Construção.

Observações metodológicas: (1) fragilidade em métricas — só acurácia em base desbalanceada (C4); (2) ausência de validação cruzada e risco de leakage pela ordem do SMOTE (C3); (3) o dataset Scania APS é o MESMO usado pelo ID7 (Selvi) — dois estudos do corpus sobre o mesmo dataset público, com focos distintos (Selvi: classificação de falha do APS; Khan: falhas de freio + XAI/SHAP e seleção de atributos).