

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 81 · Nível 2 — Análogo · Ônibus · validação full-text 16/08/2026

1. Identificação

ID (master)	81
Arquivo	81-Extracting_Invariant_Features_for_Predicting_State_of_Health_of_Batt.pdf
Título (EN)	Extracting Invariant Features for Predicting State of Health of Batteries in Hybrid Energy Buses
Título (PT)	Extração de Características Invariantes para Prever o Estado de Saúde (SoH) de Baterias em Ônibus de Energia Híbrida
Autores	Mohammed Ghaith Altarabichi; Yuantao Fan; Sepideh Pashami; Peyman Sheikholharam Mashhadi; Slawomir Nowaczyk (CAISR, Halmstad University, Suécia)
Veículo / Ano	2021 IEEE 8th International Conference on Data Science and Advanced Analytics (DSAA), 2021
DOI	10.1109/DSAA53316.2021.9564184
Palavras-chave	State of Health Estimation; Remaining Useful Life Prediction; Invariant Features; Lithium-ion Battery; Transfer Learning; Electric vehicles; Predictive maintenance
Datas	Conferência DSAA 2021; financiamento Vinnova - projeto EVE

2. Resumo traduzido (PT)

As baterias são componente crítico de segurança e o mais caro dos veículos elétricos (VEs). Para garantir a confiabilidade dos VEs, é crucial monitorar o estado de saúde (SoH) dessas baterias; monitorar sua deterioração também é relevante para a sustentabilidade do transporte (estratégia de segunda vida). Ônibus elétricos, como outros VEs, têm muitas variantes com diferentes configurações e condições operacionais. Desenvolver novos modelos de degradação para cada combinação é desafiador (indisponibilidade de dados de falha para novas configurações, heterogeneidade, baixo volume de dados para configurações menos comuns, falta de conhecimento de engenharia). Assim, transferir automaticamente um modelo de ML para novas configurações é crucial; o objetivo é extrair características invariantes entre configurações. Propõe-se um método evolutivo (GADIF) que seleciona um conjunto de características para maximizar a invariância entre configurações. Um algoritmo genético, com cromossomo binário de seleção de características, é equipado com função de aptidão que engloba desempenho na tarefa e desvio de domínio (domain shift). Compara-se o desempenho, na migração para domínios não vistos, contra métodos clássicos sem transfer learning. Os resultados mostram que usar características invariantes leva a melhor generalização para domínio não visto.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Algoritmo Genético (variante CHC) para seleção de características invariantes de domínio - GADIF; Transfer Learning / adaptação de domínio; seleção wrapper; regressão linear como modelo base; baselines: Pearson, Random Forest, XGBoost, Linear Regression, SFS e GA convencional
Paradigma (SQ.3)	Supervisionado (regressão de SoH no domínio-fonte) com adaptação de domínio (alvo não rotulado; transdutivo)
Ferramentas	Python; scikit-learn; mlxtend (SFS); algoritmo genético CHC (Eshelman, 1991)
Métricas (SQ.4/C4)	MAE (Mean Absolute Error) da regressão de SoH, com desvio-padrão sob 4-fold CV no nível de veículo
Dataset (C2)	~1500 veículos híbridos (ônibus) com leituras de sensores onboard; configurações físicas distintas (single-decker, double-decker, articulado) e condições operacionais por velocidade média (slow/moderate/fast). Características numéricas (total time, hybrid time/distance, electrical time, ESS age, diesel time/distance, charge time). SoH da BMU; idade do ESS pós-processada com registros de reparo. Dados reais de campo (Vinnova/EVE) - proprietários
Validação (C3)	Leave-one-domain-out CV na função de aptidão (domínio-alvo não visto e não rotulado); 4-fold CV no nível de veículo (mitiga vazamento entre veículos); 6 cenários de transferência (3 operacionais, 3 físicos)
Melhor modelo/resultado	GADIF - supera métodos clássicos em 4 de 6 cenários; MAE do GADIF: Slow 1,54 / Moderate 1,65 / Fast 1,96; Single-decker 2,27 / Double-decker 1,53 / Articulated 1,67

4. Questões secundárias (evidência)

SQ.1 Benefícios	Redução do MAE na predição de SoH em domínios não vistos frente a métodos clássicos e melhor generalização em 4/6 cenários. Qualitativos: prolongar vida útil da bateria (componente mais caro), viabilizar segunda vida, apoiar planejamento via RUL/EOL, reduzir custo. NÃO quantifica redução de custo/downtime — só melhoria de erro
SQ.5 Código	Não compartilha o código do GADIF (sem repositório). Apenas bibliotecas de terceiros citadas
SQ.6 Dados	Dados proprietários de frota real (~1500 ônibus, projeto Vinnova EVE). Não públicos
SQ.7 Desafios	Indisponibilidade de dados de falha p/ novas configurações; heterogeneidade e baixo volume; falta de conhecimento de engenharia; dataset shift (covariate/concept); risco de transferência negativa; SoH depende da BMU (pode falhar/ser substituída); gerações de bateria com definições distintas; incerteza por escassez histórica
SQ.8 Lacunas/futuro	Poucos trabalhos sobre seleção de características invariantes p/ SoH sob transfer learning quando a condição/configuração do alvo difere da fonte. Cenário 4 (fonte só com estrutura pesada, alvo simples) teve desempenho inferior - transferência a partir de fontes pouco variadas é fraca. Futuro: melhorar transferência com baixa variação da fonte; estender além da regressão linear; identificar características causais/invariantes

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	§III-IV.A: algoritmo nomeado (GADIF/CHC), função de aptidão formalizada (Eq.1 com alfa de tradeoff), leave-one-domain-out, modelo base e pré-processamento descritos. Confirma 1. Ressalva: parâmetros operacionais do GA (população, gerações, taxas) e valor de alfa não informados
C2 Dados	0.5	1	§IV: origem e magnitude explícitas (~1500 ônibus, dados reais Vinnova EVE) e características listadas. Desbalanceamento N/A (regressão); a heterogeneidade/escassez entre domínios — análogo do desbalanceamento — é tratada via leave-one-domain-out e seleção invariante. Sobe 0,5→1. Caveat: caracterização coarse
C3 Validação	0.5	1	Validação robusta: leave-one-domain-out CV com alvo não visto/não rotulado (out-of-distribution) + 4-fold CV no nível de veículo (mitiga vazamento). Seis cenários. Mais rigorosa que split simples; sobe 0,5→1. Sem split temporal, mas o desenho por domínio é mais adequado
C4 Métricas	0.5	0.5	MAE adequada p/ regressão de SoH, com desvio-padrão sobre 4-fold CV e comparação entre 7 métodos/6 cenários. Limitação: métrica única, sem RMSE/R2/erro relativo. Mantém 0,5
C5 Impacto/frota	0.5	1	Impacto prático forte (bateria = componente mais caro; segunda vida; planejamento via RUL/EOL) em frota real de ~1500 ônibus. Alta transferibilidade a E&C: transferir modelo de degradação/PdM entre configurações heterogêneas sem dados de falha é exatamente o cenário de frotas pesadas de E&C. Sobe 0,5→1
C6 Reprodutib.	0	0	Sem repositório de código do GADIF nem dados públicos (frota proprietária Vinnova EVE). Bibliotecas de terceiros não bastam. Confirma 0

Total: 3.0 (Moderada) → 4.5 (Alta).

Mudanças vs 1ª passagem: Três ajustes para cima: C2 0,5→1 (origem/tamanho claros; desbalanceamento N/A e heterogeneidade entre domínios tratada); C3 0,5→1 (leave-one-domain-out CV + 4-fold no nível de veículo + alvo não visto); C5 0,5→1 (impacto forte + alta transferibilidade a E&C). C1, C4, C6 mantidos. Total 3,0→4,5; Moderada→Alta

6. Alerta de escopo / observações

Escopo: O ativo monitorado é a BATERIA (SoH/RUL), não falha mecânica clássica; ainda assim é PdM (Index Terms citam Predictive maintenance/RUL/SoH) e aplica-se a frota de ~1500 ônibus (Nível 2 — Análogo). Ressalvas: (i) setor é transporte urbano de passageiros, não E&C — transferibilidade conceitual (mesmo domain shift); (ii) foco em baterias é mais aderente a frotas ELÉTRICAS, ainda incipientes em E&C

Observações: Peer-reviewed (IEEE DSAA 2021). Técnica da 1ª passagem confirmada: GA/CHC + transfer learning. Paradigma supervisionado (regressão), com alvo não rotulado (adaptação de domínio). Melhor método próprio: GADIF (vence clássicos em 4/6).