

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 84 · Nível 2 — Análogo · Ônibus · validação full-text 16/08/2026

1. Identificação

ID (master)	84
Arquivo	84-A Reproducible Pipeline for Leveraging Operational.pdf
Título (EN)	A Reproducible Pipeline for Leveraging Operational Data Through Machine Learning in Digitally Emerging Urban Bus Fleets
Título (PT)	Um Pipeline Reprodutível para Aproveitar Dados Operacionais por meio de Aprendizado de Máquina em Frotas de Ônibus Urbanos em Emergência Digital
Autores	Bernardo Tormos; Vicente Bermúdez; Ramón Sánchez-Márquez; Jorge Alvis (CMT-Clean Mobility & Thermofluids, Universitat Politècnica de València, Espanha)
Veículo / Ano	Applied Sciences (MDPI), 2025, vol. 15, art. 8395 (acesso aberto, CC BY), 2025
DOI	10.3390/app15158395
Palavras-chave	urban bus fleets; machine learning; data scarcity; data-driven maintenance; fleet digitalization; scheduled batch retraining
Datas	Recebido 20/06/2025; revisado 22/07/2025; aceito 24/07/2025; publicado 29/07/2025

2. Resumo traduzido (PT)

A adoção de manutenção preditiva no transporte público tem ganhado atenção crescente no contexto da Indústria 4.0. Contudo, muitas frotas de ônibus urbanos permanecem em estágios iniciais de transformação digital, com dados históricos limitados e infraestruturas fragmentadas que dificultam estratégias orientadas por dados. Este estudo propõe um pipeline reprodutível de ML adaptado a condições de escassez de dados, integrando engenharia de atributos informada pelo domínio, modelos leves e interpretáveis (Regressão Linear, Ridge, Árvores de Decisão, KNN), SMOGN para desbalanceamento e Validação Cruzada Leave-One-Out. Uma estratégia de retreinamento em lote agendado é incorporada para adaptar o modelo à medida que novos dados surgem. O pipeline é validado com dados reais de ônibus diesel híbridos, focando na previsão do tempo de permanência em zonas críticas de acúmulo de fuligem do Filtro de Partículas Diesel (DPF). Na Zona 4, o modelo continuou a superar a baseline no teste de produção; na Zona 3, o desempenho deteriorou ao longo do tempo, disparando retreinamento. Os resultados confirmam a capacidade do pipeline de detectar deriva (drift) e apoiar decisões de PdM sob restrições operacionais em evolução, oferecendo solução escalável para frotas em emergência digital.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Regressão Linear, Ridge, Árvore de Decisão e KNN (regressão supervisionada); RobustScaler; SMOGN (aumento de dados p/ regressão desbalanceada, só no treino); LOOCV; grid search; engenharia de atributos (Fuel Intensity Index, Prev Delta); retreinamento em lote agendado; interpretabilidade (coeficientes, regras de árvore, permutation importance)
Paradigma (SQ.3)	Supervisionado (regressão — previsão da duração nas Zonas 3 e 4 de fuligem)
Ferramentas	Python 3.12.7; scikit-learn; pandas; matplotlib; ydata-profiling (EDA); biblioteca SMOGN
Métricas (SQ.4/C4)	R2, MAE e RMSE; diagnósticos visuais (real vs previsto, resíduos); permutation importance; comparação contra baseline (previsor da média)
Dataset (C2)	Frota de 164 ônibus diesel híbridos (EURO VI-D); aquisição via OBDII + telemática (até 99 variáveis de pós-tratamento; subconjunto por conhecimento de domínio). Amostras pequenas após limpeza — Zona 3: 45 treino + 27 produção; Zona 4: 32 treino + 16 produção. Baixa frequência de amostragem (10-30 min). Escassez/desbalanceamento tratados com SMOGN. Dados públicos no Mendeley Data (DOI 10.17632/3sk43brs4p.1)
Validação (C3)	LOOCV como estratégia principal (justificada pela escassez); teste de produção com lote de ~1 mês totalmente retido (split temporal / proxy de cenário futuro); controle explícito de vazamento (SMOGN só no treino; teste só com observações reais); grid search para hiperparâmetros
Melhor modelo/resultado	KNN (n_neighbors=3). Validação — Zona 3: R2≈0,60; Zona 4: R2≈0,72. Produção — Zona 4 manteve vantagem sobre baseline (R2≈0,24); Zona 3 degradou abaixo da baseline (R2≈-0,10), disparando retreinamento

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios operacionais (passar de reativa/agendada para preditiva; maximizar uso de componentes; reduzir interrupções). Ganhos mensurados são de acurácia (não financeiros): Zona 4 (validação) reduziu MAE em 0,64 h e RMSE em 0,61 h vs baseline. Sem cifras de custo/disponibilidade
SQ.5 Código	SIM — código completo (pré-processamento, pipeline, validação) público no Zenodo (DOI 10.5281/zenodo.15874832)
SQ.6 Dados	SIM — dados abertos no Mendeley Data (DOI 10.17632/3sk43brs4p.1)
SQ.7 Desafios	Escassez e acúmulo lento de dados; baixa frequência de amostragem (OBDII); data drift (rotas, tráfego, condução); alta variância do KNN com k=3 em dataset pequeno; sub-representação de eventos curtos; qualidade de dados; baixa expertise técnica e alto investimento inicial
SQ.8 Lacunas/futuro	Lacuna central: falta de pipelines claros, reproduzíveis e open-source para equipes de manutenção sob escassez de dados. Futuro: deploy online via API de telemática; ingestão automatizada; dashboard/notificações; escalar para ensembles/redes neurais; migrar de LOOCV p/ k-fold; adaptar a outras frotas urbanas

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	Método altamente detalhado (§2.3-2.7): 4 algoritmos, RobustScaler, SMOGN, engenharia de atributos com fórmulas, grid search e hiperparâmetros ótimos explícitos (Tabelas 5-6; KNN n_neighbors=3; DT max_depth=2). Confirma 1
C2 Dados	1	1	Origem clara (§2.2: 164 ônibus EURO VI-D, rede pública real) e tamanho preciso (Tabela 4). Desbalanceamento/escassez tratados com SMOGN só no treino. Confirma 1
C3 Validação	1	1	Validação exemplar (§2.6, 3.3): LOOCV + lote de produção de ~1 mês retido (split temporal) + controle explícito de vazamento (SMOGN só no treino). Confirma 1
C4 Métricas	1	1	Métricas adequadas p/ regressão (R2, MAE, RMSE) com fórmulas, comparação contra baseline, resíduos e permutation importance. Confirma 1
C5 Impacto/frota	1	1	Forte impacto prático (§3.3, 4): estudo de caso real, apoio à decisão do gestor de frota, retreinamento agendado e detecção de drift. Metodologia (frota diesel pesada sob escassez, modelos leves, SMOGN, LOOCV) diretamente transferível a frotas de E&C. Ressalva: o artigo discute transferibilidade só a outras frotas de transporte urbano. Confirma 1
C6 Reprodutib.	1	1	Reprodutibilidade máxima: código público no Zenodo E dados públicos no Mendeley; artigo desenhado em torno da reprodutibilidade. Confirma 1

Total: 6.0 (Alta) → 6.0 (Alta).

Mudanças vs 1ª passagem: As seis notas da 1ª passagem foram integralmente CONFIRMADAS. Total mantido 6,0 (Alta). O full-text reforça C3 (split temporal + tratamento de vazamento) e C6 (código e dados públicos com DOIs)

6. Alerta de escopo / observações

Escopo: PdM com ML em frota pesada/comercial (ônibus urbanos), coerente com Nível 2 (Análogo). Registro: domínio = transporte público urbano, não E&C; a transferibilidade é discutida pelos autores só para frotas de trânsito, sem menção a E&C/heavy equipment. Alvo modelado = duração em zonas de fuligem do DPF (proxy de manutenção/regeneração), não falha direta de componente

Observações: Periódico MDPI Applied Sciences (acesso aberto), fora do IEEE Xplore — provavelmente de Scopus/WoS ou busca complementar. KNN é o melhor modelo. Ponto forte: raro exemplar com código E dados públicos + split temporal + tratamento de drift, referência metodológica de reprodutibilidade. Amostras muito pequenas (N=16 a 45) são limitação reconhecida, mas não afetam C1-C6 dado o tratamento (SMOGN, LOOCV) e a transparência.