

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 97 · Nível 2 — Análogo · Frota terrestre · validação full-text 16/08/2026

1. Identificação

ID (master)	97
Arquivo	009-Machine_Learning-Driven_RAM_Analysis_Using_Multi-variate_Sensor_Data.pdf
Título (EN)	Machine Learning-Driven RAM Analysis Using Multi-variate Sensor Data
Título (PT)	Análise RAM (Confiabilidade, Disponibilidade e Manutenibilidade) Guiada por Aprendizado de Máquina Utilizando Dados Multivariados de Sensores
Autores	Guga Gugaratshan; Dakota Barthlow; Dan (Daniel J.) Lingenfelser; Balaje Thumati (Hottinger Brüel & Kjaer / HBK)
Veículo / Ano	2023 Annual Reliability and Maintainability Symposium (RAMS), 2023
DOI	10.1109/RAMS51473.2023.10088229
Palavras-chave	Reliability; machine learning; multivariate analysis; diagnostics; prognostics; sensor data; outlier detection
Datas	Publicação 2023 (RAMS); baixado do IEEE Xplore em 02/02/2026

2. Resumo traduzido (PT)

Com a proliferação de sensores baratos e dispositivos de coleta, tornou-se mais fácil coletar dados de uso em tempo real de equipamentos em serviço, gerando abundância de séries temporais (temperatura, fluxo, vibração, deformação etc.). A análise tradicional de dados de vida (ensaios acelerados ou tempo-até-falha) pode ser aprimorada com esses novos dados para melhorar confiabilidade, desempenho e custo do ativo. O artigo apresenta um método simples para incorporar séries temporais coletadas de uma frota de veículos terrestres, atualizando distribuições de confiabilidade previamente calculadas para subsistemas (freio, motor). Por meio dessa estimação contínua, a manutenção de subsistemas pode ser otimizada. Os dados são modelados com modelos de ML que estabelecem um perfil de desempenho no nível do veículo/subsistema; os clusters são enriquecidos com bases textuais de manutenção ou opinião de especialista. As features são derivadas por momentos de ordem superior e estatísticas descritivas. Uma anomalia potencial (ex. falha de freio) pode ser detectada; quando detectada, atualiza-se o escore de confiabilidade. Esse laço contínuo de perfilamento, estimação de confiabilidade e prognóstico ajuda a determinar proativamente necessidades de manutenção. A metodologia é demonstrada com dados reais de uma frota de veículos terrestres, com melhora significativa na detecção de falhas.

3. Técnicas, dados e validação

Técnicas (SQ.2)	MLP (perceptron multicamadas) para prever um canal a partir dos demais e analisar o resíduo; detecção de outliers/anomalias por k-means, PCA, Isolation Forest e Random Forest (ensemble); inferência bayesiana combinando prior populacional + verossimilhança (sensor) para atualizar a vida confiável; engenharia de confiabilidade RAM (Weibull/exponencial, MTBF, vida B10); features via momentos de ordem superior
Paradigma (SQ.3)	Híbrido — não-supervisionado (anomalia: k-means, Isolation Forest, PCA) + supervisionado (MLP em regressão canal-a-canal; RF), integrado a inferência bayesiana e confiabilidade clássica
Ferramentas	ReliaSoft Weibull++ (comercial) para PDF/análise de vida; algoritmos de ML sem framework declarado
Métricas (SQ.4/C4)	Teste-t (horas em alta rotação entre veículos com/sem falha, $p=0,0036$); eficácia (TPR) ~55% da detecção de outliers; prior de falha 60%; posterior: probabilidade de falha do freio 42%. NÃO há métricas padrão de ML (acurácia/precisão/recall/F1/AUC/RMSE); valores ilustrativos e ofuscados
Dataset (C2)	18 veículos selecionados de um banco de frota; 7 com indicação de falha do freio de escape; Tabela 1 (teste-t) lista 9 vs 9 amostras de horas de alta rotação normalizadas; caminho rodoviário com motor CAT C7; sinais multivariados (velocidade, boost, carga do motor, taxa de combustível, pedal, rotação, contrapressão de escape); dados normalizados/ofuscados; N pequeno; desbalanceamento não tratado
Validação (C3)	Teste-t estatístico; concordância entre múltiplos detectores (ensemble); validação de campo (inspeção da válvula por técnicos); contrapressão de escape p/ rotular falha; análise de resíduo do MLP. NÃO há CV, NÃO há teste separado formal, sem split temporal; risco de vazamento não discutido

Melhor modelo/resultado	MLP feed-forward (contrapressão de escape) + ensemble de detecção de outliers, integrados por inferência bayesiana; k-means como ilustração. Sem comparação quantitativa entre modelos
--------------------------------	--

4. Questões secundárias (evidência)

SQ.1 Benefícios	Detecção precoce de falha (freio de escape por engine slobber); priorização de manutenção por subsistema; atualização contínua da vida confiável (B10) por ativo individual; melhora na detecção de falhas. Reportados QUALITATIVAMENTE — sem quantificação de custo/disponibilidade; estimativas ofuscadas
SQ.5 Código	Não — nenhum código/repositório
SQ.6 Dados	Não — dados proprietários, normalizados/ofuscados; autores declaram não poder publicar os dados reais
SQ.7 Desafios	Dificuldade de obter datasets validados em campo (rótulos), exigindo análise de engenharia; nem todo outlier indica falha (pode ser novo ponto de operação); seleção do canal/sinal muito desafiadora; necessidade de grande volume para cobrir a faixa operacional; amostra pequena; dependência de técnicos de campo
SQ.8 Lacunas/futuro	Integrar múltiplos datasets; estender a muitos canais e frotas maiores; substituir estimativas pontuais por PDFs na inferência bayesiana; integração com FMEA/RCM/FEA/fadiga; validação de campo mais ampla

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	0.5	§3-5: algoritmos nomeados (MLP, k-means, PCA, Isolation Forest, RF, bayesiana Eq.1), pré-proc. (momentos/estatísticas, normalização) e processo em 7 passos. Porém NENHUM parâmetro/hiperparâmetro (arquitetura MLP, k do k-means) e valores ilustrativos/ofuscados. Método claro conceitualmente, não parametrizado — 0,5
C2 Dados	1	0.5	§4: origem clara (frota de veículos terrestres, caminhão CAT C7) e tamanho informado (18 veículos; 7 com falha; 9 vs 9). Contudo o desbalanceamento NÃO é tratado nem justificado como N/A, N pequeno e dados ofuscados. 0,5
C3 Validação	0.5	0.5	Validação estatística (teste-t $p=0,0036$), ensemble, validação de campo e resíduo do MLP; porém sem CV, sem teste separado formal, sem split temporal e sem discussão de vazamento — 0,5
C4 Métricas	0	0	Reporta teste-t e probabilidades bayesianas e uma TPR ~55%, mas são estimativas/insumos assumidos e ofuscados, não métricas de avaliação em teste. Ausentes acurácia/precisão/recall/F1/AUC/RMSE — 0
C5 Impacto/frota	0.5	0.5	Aplicação a frota central (PdM de subsistemas, manutenção proativa). Transferibilidade a E&C ALTA (veículos terrestres pesados, motor CAT/Caterpillar dominante em construção). Porém benefício demonstrado como prova de conceito qualitativa — 0,5
C6 Reprodutib.	0	0	Sem código e sem dados públicos (proprietários/ofuscados; autores dizem não poder publicar); única ferramenta citada é comercial (Weibull++). Reprodutibilidade nula — 0

Total: 3.0 (Moderada) → 2.0 (Baixa).

Mudanças vs 1ª passagem: Baixa de 3,0 para 2,0: (1) C1 1→0,5 (algoritmos/fluxo claros, mas sem qualquer parâmetro/hiperparâmetro e valores ofuscados); (2) C2 1→0,5 (origem/tamanho presentes, mas desbalanceamento não tratado, N pequeno, dados ofuscados). C3, C4, C5, C6 confirmados. Faixa Moderada→Baixa (2,0 no limite superior de Baixa)

6. Alerta de escopo / observações

Escopo: Nível 2 — Análogo: frota terrestre pesada/comercial (caminhão rodoviário, motor CAT C7), aplicações militar/comercial, não especificamente E&C — por isso Análogo, não Núcleo. Transferibilidade a E&C forte (motores Caterpillar comuns em construção).

Observações: Prova de conceito do RAMS 2023 (6 pág.), da HBK. Contribuição metodológica: combinar confiabilidade clássica (bayesiana + Weibull/MTBF/B10) com detecção de anomalias por ML para atualizar a confiabilidade por ativo. Foco no freio de escape (engine slobber). Rigor de ML limitado (sem CV, sem métricas de modelo, dados ofuscados, sem código) rebaixa a qualidade apesar da forte aderência ao tema.