

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 107 · Nível 2 — Análogo · Ferroviário/Metrô · validação full-text 16/08/2026

1. Identificação

ID (master)	107
Arquivo	020-Multidimensional_Edge_Perception_Model_for_Rail_Vehicle_Operational_States_Based_o.pdf
Título (EN)	Multidimensional Edge Perception Model for Rail Vehicle Operational States Based on Artificial Intelligence of Things
Título (PT)	Modelo de Percepção Multidimensional na Borda (Edge) para Estados Operacionais de Veículos Ferroviários Baseado em Inteligência Artificial das Coisas (AloT)
Autores	Shaoze Zhou; Tianshuo Guo; Xingsen Luan; Yonghua Li (School of Rolling Stock Engineering, Dalian Jiaotong University, China)
Veículo / Ano	IEEE Internet of Things Journal, vol. 11, no. 18, 15 set. 2024, pp. 29728-29741, 2024
DOI	10.1109/JIOT.2024.3405356
Palavras-chave	AloT; MLP; estados operacionais; PHM; veículo ferroviário; TinyML
Datas	Recebido 31/01/2024; aceito 18/05/2024; publicado 24/05/2024

2. Resumo traduzido (PT)

No domínio do prognóstico e gestão de saúde (PHM) para veículos ferroviários inteligentes, a percepção multidimensional em tempo real é crucial para o monitoramento. Contudo, obtê-la em dispositivos IoT de baixo custo e capacidade limitada é um desafio. Diante da falta de modelos eficazes e da crescente demanda por análise de dados de PHM, este estudo propõe um modelo de percepção não invasivo, multidimensional, baseado em AloT, para melhorar o desempenho do veículo e a manutenção preditiva. O modelo usa TinyML para implantar um modelo leve nos dispositivos de borda dos veículos ferroviários, reconhecendo em tempo real os estados operacionais ao monitorar dados multidimensionais como aceleração e ângulo de inclinação, e transmite os resultados à nuvem IoT para fusão e estatísticas. Experimentos em ambiente de metrô mostram reconhecimento de nove estados operacionais complexos, em modo tempo real e offline, com acurácia superior a 97%, significativamente melhor que o MLP tradicional. O reconhecimento de dois eixos supera métodos de eixo único e de três eixos e exibe forte robustez sob vibração. A versatilidade permite extensão a diferentes sensores e à detecção de estados de falha, aplicável ao monitoramento inteligente de diversos sistemas de transporte e maquinário.

3. Técnicas, dados e validação

Técnicas (SQ.2)	TinyML com MLP multidimensional (perceptron multicamadas) implantado na borda via AloT; conversão para TensorFlow Lite. Pré-processamento: correção de zero-drift, filtro de Kalman para inclinação, janela deslizante, normalização, one-hot, dropout 50%
Paradigma (SQ.3)	Supervisionado — classificação multiclasse (9 estados operacionais; entropia cruzada)
Ferramentas	Python 3.10; TensorFlow 2.4; Keras; NumPy; Matplotlib; TFLite. Hardware: ESP32, acelerômetro ADXL345, MPU6050. Treino em i7-12700H + GTX 3060
Métricas (SQ.4/C4)	Acurácia (principal); função de perda (entropia cruzada); matrizes de confusão por classe. NÃO reporta precisão, recall nem F1
Dataset (C2)	Coleta própria em vagão de metrô via AloT a 20 Hz: >100.000 registros de aceleração e inclinação. Split 80/20. Janela de 2s = 40 pontos. Teste offline: 367.240 amostras de DOIS veículos diferentes na mesma linha em 3 dias. Origem/tamanho bem descritos; desbalanceamento entre as 9 classes NÃO tratado
Validação (C3)	Split 80/20; dois conjuntos de teste independentes (7 estados de aceleração); experimento de robustez com vibração; teste online em tempo real (2.766 reconhecimentos) e teste offline em veículos/dias diferentes (365k+ amostras) = validação praticamente externa. Sem CV k-fold nem split temporal explícito. Risco de vazamento: janelas sobrepostas (~75%) embaralhadas antes do split, mitigado pelos testes independentes
Melhor modelo/resultado	MLP multidimensional com dois eixos (x,z): treino 98,63% / validação 98,02% (vs MLP tradicional 94,03%/92,65%); teste 97,3% e 97,1%; modelo de inclinação 99,83%; online 96,29% (aceleração) e 99,5% (inclinação); offline 98,09%

4. Questões secundárias (evidência)

SQ.1 Benefícios	Acurácia >97% (vs ~92-94% do MLP tradicional); redução drástica de volume transmitido (resultado = 1 inteiro em vez de floats); baixo consumo (bateria dura ~meio mês); hardware compacto não invasivo; dois eixos reduzem carga/latência. Benefícios de PHM: reduzir paradas, otimizar planos de manutenção, eficiência energética, segurança
SQ.5 Código	NÃO compartilhado (só a pilha de software é citada)
SQ.6 Dados	NÃO compartilhado (dados proprietários de metrô)
SQ.7 Desafios	Baixa diversidade/dimensionalidade de sensores; falta de dados de estados de FALHA (reconhece estados operacionais normais, não falhas reais); overfitting em estados complexos (mitigado com dropout); zero-drift e erro de ângulo (compensação + Kalman); queda de robustez sob vibração severa (~89,7-92,4%); sensores caros e processamento centralizado geram latência/consumo
SQ.8 Lacunas/futuro	Escassez de pesquisa sobre ML para percepção em tempo real de estados operacionais ferroviários na borda. Futuro: integrar mais tipos de sensores; coletar e treinar dados de estados de FALHA (motor, mola pneumática) p/ diagnóstico e PdM; expandir a outros domínios de transporte/maquinário

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	§III detalha algoritmo (MLP/TinyML), pré-proc. (zero-drift, Kalman, janela, normalização, one-hot) e parâmetros: arquitetura em Tabela I (dense 32-8-8-dropout-7; 3.511 params), ReLU, Softmax, dropout 50%, Adam (lr=0,001), 1500 iterações, janela 2s a 20 Hz. Replicável. Confirma 1
C2 Dados	1	0.5	Origem/tamanho muito bem descritos (>100k registros; offline 367.240 amostras de 2 veículos/3 dias; split 80/20). PORÉM o desbalanceamento entre as 9 classes (estados transitórios raros) NÃO é tratado nem justificado; a janela deslizante serve a augmentation geral, não a balanceamento. Reduz 1→0,5
C3 Validação	1	1	§IV: split 80/20 + 2 test sets independentes + teste de robustez + teste online e offline em DOIS veículos/3 dias (validação praticamente externa). Ressalva: sem CV k-fold e risco de vazamento por janelas sobrepostas embaralhadas antes do split, mas substancialmente mitigado por dados independentes. Mantém 1
C4 Métricas	0.5	0.5	Métricas adequadas (acurácia, entropia cruzada, matrizes de confusão por classe), mas INCOMPLETAS: sem precisão/recall/F1 em cenário multiclasse potencialmente desbalanceado. Meia nota
C5 Impacto/frota	0.5	0.5	Impacto em frota ferroviária forte e concreto (sistema real, baixo custo, não invasivo; casos de PHM: desgaste de roda em curvas, suspensão, freio). Sendo Análogo, a transferibilidade a E&C aparece genérica ('sistemas de transporte e maquinário'), sem menção a construção. Mantém 0,5
C6 Reprodutib.	0	0	Sem código público e sem dados públicos. Citação da pilha não caracteriza reprodutibilidade aberta. 0

Total: 4.0 (Moderada) → 3.5 (Moderada).

Mudanças vs 1ª passagem: Única alteração: C2 1→0,5 — dataset bem documentado em origem/tamanho, mas desbalanceamento das 9 classes não tratado nem justificado. C1, C3, C4, C5, C6 confirmados. Total 4,0→3,5; faixa Moderada

6. Alerta de escopo / observações

Escopo: Ferroviário/metrô (não E&C), coerente com Nível 2 — Análogo (múltiplos veículos/vagões monitorados). Sustenta PdM/PHM + IA + frota, mas transferibilidade explícita a E&C NÃO é feita (só extensão genérica). Usar com cautela p/ inferências sobre E&C

Observações: TinyML/AIoT confirmado; algoritmo central é MLP multidimensional supervisionado embarcado. Reconhece estados OPERACIONAIS (start, aceleração, curvas), não falhas reais — a PdM é prospectiva/indireta. (1) vazamento por janelas sobrepostas embaralhadas antes do split; (2) sem precisão/recall/F1; (3) sem tratamento de desbalanceamento; (4) sem código/dados. Fortes: deploy real em metrô, testes online e offline em veículos independentes, robustez a vibração