

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 113 · Nível 2 — Análogo · Mineração · validação full-text 16/08/2026

1. Identificação

ID (master)	113
Arquivo	030-Mining_Haulage_Road_Maintenance_Prediction_Dashboard_Utilising_Machine_Learning_Techniques.pdf
Título (EN)	Mining Haulage Road Maintenance Prediction Dashboard Utilising Machine Learning Techniques
Título (PT)	Dashboard de Predição de Manutenção de Vias de Transporte (Haulage Roads) em Mineração Utilizando Técnicas de Aprendizado de Máquina
Autores	Brad Purdon; Lasitha Piyathilaka; Jung-Hoon Sul; Daluwathu Preethichandra (Central Queensland University, Austrália)
Veículo / Ano	2024 6th International Conference on Advancements in Computing (ICAC), IEEE, 2024
DOI	10.1109/ICAC64487.2024.10851152
Palavras-chave	predictive maintenance; machine learning; logistic regression; haulage roads; surface mining
Datas	Copyright 2024 IEEE; baixado do IEEE Xplore em 03/02/2026

2. Resumo traduzido (PT)

Este artigo detalha o desenvolvimento de um dashboard de manutenção preditiva para vias de transporte (haulage roads) em operações de mineração de superfície utilizando algoritmos de aprendizado de máquina. Avaliamos diversos modelos (Regressão Logística, Random Forest e KNN) para determinar sua eficácia em prever o momento e o local da manutenção necessária das vias. A pesquisa identifica a Regressão Logística como o mais eficaz, treinado com dados que incluem medições de vibração, contagens de equipamentos e métricas de velocidade para avaliar as condições da superfície da via. Essas entradas são processadas por uma função logística para estimar a probabilidade de reparos necessários. As previsões são armazenadas em um banco SQL e visualizadas via Power BI, com interface amigável que permite a operadores (inclusive de experiência limitada) interpretar os dados e tomar decisões de manutenção informadas, melhorando eficiência operacional e segurança.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Regressão Logística (melhor); Random Forest; K-Nearest Neighbors (KNN)
Paradigma (SQ.3)	Supervisionado (classificação binária repair/no-repair; rótulos 0/1 por especialistas via inspeção visual; limiar 0.4/0.8 para três classes)
Ferramentas	AWS Amazon SageMaker (treino/deploy); Microsoft Power BI (dashboard); banco SQL; acelerômetro triaxial (embarcado e app de celular); beacons/GPS
Métricas (SQ.4/C4)	Accuracy, Precision, Recall e F1-score (Tabela I) + verificação qualitativa por inspeção manual in situ
Dataset (C2)	~110.000 pontos de vibração e ~140.000 de equipamento, coletados em janela móvel de 7 dias em mina de superfície real; features por segmento de via (max/min/desvio de vibração, horas desde último reparo, contagem de veículos, velocidade média); split 80/20 com shuffle
Validação (C3)	Hold-out 80/20 com embaralhamento + validação qualitativa por comparação com inspeções manuais/auditorias in-pit; SEM validação cruzada e SEM split temporal
Melhor modelo/resultado	Regressão Logística — Accuracy 82%, Precision 94%, Recall 83%, F1 0,88 (superou RF e KNN, ambos 77%)

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios mensuráveis restritos ao desempenho (LR: Acc 82%, Prec 94%, Rec 83%, F1 0,88). Operacionais (segurança, eficiência, custo, manutenção proativa, priorização de reparos em rampas) apenas QUALITATIVOS
SQ.5 Código	Não há compartilhamento de código; só ferramentas proprietárias (SageMaker, Power BI, SQL)
SQ.6 Dados	Não há compartilhamento de dados (mina de superfície real, proprietários)
SQ.7 Desafios	(i) monitoramento em tempo real só detecta após ocorrido (intervenção tardia); (ii) alto custo de equipar toda a frota; (iii) layout muda com o avanço da lavra (mitigado por beacons GPS); (iv) rotulagem por julgamento humano; (v) limitação do KNN em dados grandes. Discute pouco as próprias limitações (não aborda vazamento por shuffle)

SQ.8 Lacunas/futuro	Futuro: incorporar clima em tempo real e histórico de manutenção; investigar ensemble e deep learning p/ melhorar desempenho/generalização
----------------------------	--

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	Algoritmos nomeados (§IV) e pré-proc./feature engineering ricos (§III.A-F: segmentação por GPS, features de vibração, horas desde último reparo, contagem, velocidade, timestamp como chave); limiares 0.4/0.8. Ressalva: sem hiperparâmetros (k do KNN, n_estimators do RF, regularização da LR)
C2 Dados	0.5	0.5	Tamanho (~110k/~140k, janela de 7 dias) e origem (mina real, acelerômetros embarcados e de celular, GPS) bem descritos. Porém NÃO trata desbalanceamento (provável predominância de 'no repair') e NÃO informa nº de segmentos/instâncias rotuladas
C3 Validação	0.5	0.5	Teste separado (80/20) + validação qualitativa por inspeção manual, mas SEM CV e SEM split temporal. O shuffle antes do split em dado inerentemente temporal levanta risco de vazamento, não discutido
C4 Métricas	0	1	DIVERGE (0→1). Tabela I reporta Accuracy/Precision/Recall/F1 para os três modelos — métricas pertinentes p/ classificação potencialmente desbalanceada. Baseline 0 não capturou a Tabela I. Ressalva: sem AUC/matriz de confusão; typo 'Precesion'
C5 Impacto/frota	0.5	1	DIVERGE (0,5→1). Sistema implantado (LR no SageMaker, dashboard Power BI operacional) em mina real, com engajamento de stakeholders e validação por auditorias in-pit. Transferibilidade a E&C plausível (equipamentos pesados em vias não pavimentadas de canteiro)
C6 Reprodutib.	0	0	Nem código nem dados públicos (mina proprietária). Reprodutibilidade nula

Total: 2.5 (Moderada) → 4.0 (Moderada).

Mudanças vs 1ª passagem: Duas mudanças: C4 0→1 (Tabela I traz Accuracy/Precision/Recall/F1) e C5 0,5→1 (deploy real e validado em mina). C1, C2, C3, C6 confirmados. Total 2,5 (Baixa)→4,0 (Moderada)

6. Alerta de escopo / observações

Escopo: Nível 2 Análogo: o objeto da PdM é a CONDIÇÃO DA VIA (haulage road), NÃO componentes do veículo. A frota (caminhões + celulares com acelerômetro) é PLATAFORMA MÓVEL DE SENSORIAMENTO, não alvo da PdM. É PdM de INFRAESTRUTURA via telemetria de frota. Transferibilidade a E&C = monitoramento de vias/rotas de canteiro por vibração de veículos pesados. Recomenda-se marcar como 'PdM de via/infraestrutura' na síntese para não inflar a contagem de PdM de componentes de frota

Observações: RF e KNN empatam em 77%; LR vence em tudo. Rótulos originais são probabilidades 0-1 de especialistas, binarizadas/limiarizadas (0.4/0.8) em 3 classes. Typo 'Precesion' na Tabela I. Dado temporal tratado com shuffle.