

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 125 · Nível 2 — Análogo · Ferroviário/Metrô · validação full-text 16/08/2026

1. Identificação

ID (master)	125
Arquivo	125-Predictive_Maintenance_Framework_for_Urban_Metro_Vehicles.pdf
Título (EN)	Predictive Maintenance Framework for Urban Metro Vehicles
Título (PT)	Framework de Manutenção Preditiva para Veículos de Metrô Urbano
Autores	Sarvesh Barapatre; Shweta Tiwaskar; Omkar Gangurde; Rohit Bibwe (Vishwakarma Institute of Information Technology, Pune, Índia)
Veículo / Ano	2024 5th International Conference for Emerging Technology (INCET), Karnataka, Índia — IEEE, 2024
DOI	10.1109/INCET61516.2024.10593614
Palavras-chave	Predictive maintenance (PdM); Machine Learning; Failure prediction; XGBoost; Logistic regression
Datas	Conferência 24-26/05/2024; baixado via USP em 21/07/2026

2. Resumo traduzido (PT)

O estudo enfatiza o papel crítico da Manutenção Preditiva (PdM) na proteção de empresas contra falhas de sistema e acidentes. Ao identificar e classificar oportunamente falhas potenciais, a PdM pode reduzir o risco de acidentes, reforçar a segurança, minimizar o downtime e melhorar a manutenção veicular. Foram utilizados dois algoritmos de ML, XGBoost e Regressão Logística, para prever a ocorrência de falhas e determinar o framework superior para tipos específicos de predição de falha. O método baseia-se no conjunto MetroPT e traz vantagens para operadores de metrô/ferrovia. Ao prever proativamente as necessidades de manutenção, a gestão pode tratar potenciais falhas antes que se tornem graves, reforçando a confiabilidade do veículo e reduzindo o downtime, garantindo um sistema de transporte mais resiliente. Os dados de sensores analógicos (pressão do tanque de ar, temperatura do óleo do compressor, valores do fluxômetro) são vitais neste framework.

3. Técnicas, dados e validação

Técnicas (SQ.2)	XGBoost e Regressão Logística; classificação binária separada por tipo de falha; undersampling da classe majoritária
Paradigma (SQ.3)	Supervisionado (classificação binária)
Ferramentas	Python 3.10; Google Colaboratory (12 GB RAM); XGBoost; Regressão Logística
Métricas (SQ.4/C4)	Acurácia, Precisão, Recall e F1-score por classe (Classe 0 = sem falha; Classe 1 = falha)
Dataset (C2)	MetroPT (Metro do Porto, APU de trem); ~10.979.547 pontos (também citado 10.773.588); 21 features (analógicos, digitais e GPS); sem nulos; benchmark público (Velooso et al., Scientific Data 2022, doi 10.1038/s41597-022-01877-3)
Validação (C3)	Split treino-teste 80-20 com alegação de 'integridade cronológica'; SEM validação cruzada; undersampling aplicado a cada dataframe (ordem em relação ao split não explicitada — risco de vazamento não descartado); métricas quase perfeitas sugerem overfitting/vazamento
Melhor modelo/resultado	XGBoost — superou a LR nas três falhas (air leak on clients acurácia 100% e F1 classe 1 = 1,00; air dryer acc 99%, F1 0,99; oil leak acc 88%, F1 0,83)

4. Questões secundárias (evidência)

SQ.1 Benefícios	Benefícios mensuráveis restritos ao desempenho: XGBoost F1 (classe 1) 0,99/1,00/0,83. Operacionais (downtime, custos, disponibilidade) só qualitativos; a menção de 'redução de custos de até 20%' é da referência [9], não deste trabalho
SQ.5 Código	Não compartilhado (só ambiente Colab, Python 3.10)
SQ.6 Dados	Dados públicos — MetroPT (benchmark aberto)
SQ.7 Desafios	Desbalanceamento extremo (tratado por undersampling); LR falhou na classe rara (air dryer classe 1: precisão 0,16, recall 0,06, F1 0,03); uso só de sensores analógicos (GPS/digitais descartados); ausência de CV e métricas suspeitamente perfeitas (indício de vazamento não discutido)
SQ.8 Lacunas/futuro	Futuro: com melhor qualidade de dados, algoritmos mais avançados gerariam modelos melhores; estender a outros sensores/anomalias. (Analista): sem CV, sem deploy real, sem quantificação de custo, sem estudo de transferibilidade

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	§II e IV: algoritmos claros (XGBoost/LR) e pré-proc. detalhado (limpeza, datetime, descarte de GPS, só analógicos, 80-20, undersampling com Tabelas III-V). Confirmo 1; ressalva: hiperparâmetros não reportados
C2 Dados	1	1	§IV e V: origem/tamanho explícitos (MetroPT, ~10,97 M, 21 features, sem nulos) e desbalanceamento tratado por undersampling com contagens antes/depois. Confirmo 1
C3 Validação	1	0.5	Só split 80-20 com teste separado; NÃO há CV. A alegação de 'integridade cronológica' conflita com o undersampling aleatório, e a ordem undersampling vs split não é explicitada (risco de vazamento). Métricas quase perfeitas (acc 100%, F1 1,00) reforçam suspeita não discutida. Rebaixo 1→0,5
C4 Métricas	0.5	0.5	§VI-VII: acurácia/precisão/recall/F1 por classe (inclusive minoritária), adequado p/ desbalanceada; porém sem AUC-ROC/PR-AUC, sem matriz de confusão, comparações majoritariamente em figuras. 0,5
C5 Impacto/frota	0.5	0.5	Impacto qualitativo (confiabilidade, downtime, segurança), sem quantificação própria e SEM discussão de transferibilidade a E&C (inferência do analista: sistemas pneumáticos/compressor/freios a ar análogos a equipamentos pesados). 0,5
C6 Reprodutib.	0.5	0.5	Dados públicos (MetroPT, DOI), mas código NÃO disponibilizado. Rubrica exige código E dados; 0,5

Total: 4.5 (Alta) → 4.0 (Moderada).

Mudanças vs 1ª passagem: Única alteração: C3 1→0,5 (sem CV, ambiguidade undersampling/split com risco de vazamento, métricas quase perfeitas não criticadas). Demais confirmadas. Total 4,5 (Alta)→4,0 (Moderada)

6. Alerta de escopo / observações

Escopo: Ferroviário/Metrô (Metro do Porto), não E&C — coerente com Nível 2 (Análogo); não contradiz inclusão. Frota de metrô com foco na APU/compressor, análoga a sistemas pneumáticos de equipamentos pesados.

Observações: Conferência (INCET 2024) de origem discente; boa clareza de método e tratamento de desbalanceamento, mas fragilidade na validação e reprodutibilidade parcial (só dados). Métricas de teste implausíveis (100%) devem ser lidas com cautela; citar como evidência análoga de viabilidade de XGBoost em PdM por sensores analógicos, não como benchmark de desempenho.