

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 134 · Nível 2 — Análogo · Mineração · validação full-text 16/08/2026

1. Identificação

ID (master)	134
Arquivo	052-Electrical_fault_classification_strategies_for_maintenance_models_using_machine_learning_algorithms.pdf
Título (EN)	Electrical fault classification strategies for maintenance models using machine learning algorithms
Título (PT)	Estratégias de classificação de falhas elétricas para modelos de manutenção usando algoritmos de aprendizado de máquina
Autores	Luis Felipe Rau; Marcela Jamett; Pablo Adasme (Departamento de Engenharia Elétrica, Universidad de Santiago de Chile)
Veículo / Ano	2022 IEEE International Conference on Automation/XXV Congress of the Chilean Association of Automatic Control (ICA-ACCA), 2022
DOI	10.1109/ICA-ACCA56767.2022.10006330
Palavras-chave	Condition based maintenance; Machine learning algorithm; Electrical faults
Datas	Publicado 2022; treino 01-24/fev/2021 e validação 29/jun-28/jul/2021; baixado do IEEE Xplore em 03/fev/2026

2. Resumo traduzido (PT)

Fornecedores de equipamentos de mineração estão investigando novos modelos de manutenção para os sistemas de monitoramento e controle de caminhões de mineração, com foco na eficiência do processo devido aos altos custos. O objetivo é gerar um modelo de manutenção preditiva para falhas elétricas por meio de algoritmos de ML que preveem e classificam a severidade das falhas nos chicotes elétricos (harnesses). O estudo é realizado nos chicotes do sistema de controle do componente motor a diesel de uma frota de caminhões. A análise preditiva considera dois fatores: número e tendências de falhas associadas a uma classificação proposta. Redes neurais e árvores de decisão apresentam melhor desempenho. Esses resultados determinam um modelo CBM (Manutenção Baseada em Condição) que torna o programa de manutenção mais eficiente.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Classificação supervisionada multiclasse (4 níveis: Minor/Marginal/Serious/Critical) com Decision Tree, SVM, KNN e ANN; melhores desempenhos atribuídos a redes neurais e árvores de decisão
Paradigma (SQ.3)	Supervisionado (classificação)
Ferramentas	MATLAB (Classification Learner)
Métricas (SQ.4/C4)	Apenas acurácia; todos os 4 algoritmos >95% em treino e validação
Dataset (C2)	Base tabular com 672 linhas (28 motores × 24 dias) e 2 variáveis (número de falhas/dia e gradiente relativo ao 1º dia), derivada de códigos de falha do ECM (FMI03/FMI04). Treino: motores de frota de 28 caminhões de um contrato de mineração. Validação: 12 motores de OUTRO contrato. Dados proprietários (Caterpillar/contrato). Fortemente desbalanceado (concentrado em Minor/Marginal); desbalanceamento reconhecido mas NÃO tratado
Validação (C3)	Conjunto de validação externo separado (outro contrato + outra janela temporal = split de origem e temporal, ponto forte). Sem menção explícita a CV. PREOCUPAÇÃO DE VAZAMENTO/CIRCULARIDADE: os alvos (Tabela II) são definidos por limiares determinísticos sobre as mesmas 2 variáveis usadas como features, o que reduz a tarefa a reaprender as regras de rotulagem e explica a acurácia >95%
Melhor modelo/resultado	ANN (por bom desempenho e simplicidade); todos os 4 com acurácia >95%

4. Questões secundárias (evidência)

SQ.1 Benefícios	Economia de custos de manutenção de 33% (validação) a 57% (treino) na troca de chicotes: só 42% da frota de treino (12/28) e 67% da de validação (8/12) precisariam trocar no próximo overhaul; chicote ~USD 3.370/motor; total treino cai de USD 94.382 para 40.450 e validação de 40.448 para 26.966. Substitui manutenção por horas fixas (12.000 h) por CBM. Ressalva: não
-----------------	--

	considera custo de implementação
SQ.5 Código	Não compartilhado (só menção a MATLAB)
SQ.6 Dados	Não compartilhados (proprietários de contratos de mineração; base ECM/Caterpillar)
SQ.7 Desafios	Incerteza, alta dimensionalidade e desbalanceamento (intro); falhas imprevisíveis, sem correlação linear entre nº de falhas e horas; ambientes hostis (poluição, temperatura, uso intensivo) que aceleram desgaste dos chicotes
SQ.8 Lacunas/futuro	Avaliar se muda a dinâmica das falhas e se a frequência de falhas catastróficas aumenta com o novo modelo; custo de implementação não avaliado. (Analista): sem tratamento de desbalanceamento, métrica única, circularidade feature-alvo

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	0.5	§III-IV descrevem algoritmos (DT/SVM/KNN/ANN via MATLAB) e o pré-proc./feature engineering (nº de falhas/dia, gradiente, limiares dos 4 alvos na Tabela II), mas NÃO reportam parâmetro/configuração (arquitetura da ANN, kernel do SVM, k do KNN, profundidade) nem tuning/normalização. Componente 'parâmetros' ausente. Rebaixado 1→0,5
C2 Dados	0.5	0.5	Tamanho/origem bem descritos (672 linhas; 28 motores/24 dias; contratos e datas). Porém desbalanceamento reconhecido (Fig. 9) e NÃO tratado. Confirma 0,5
C3 Validação	0.5	0.5	Forte: conjunto de validação verdadeiramente externo (outro contrato/janela). Fraco grave: circularidade/vazamento (alvos são função determinística das próprias features, Tabela II), inflando a acurácia >95%; sem CV. Compensam-se; mantém 0,5
C4 Métricas	0	0	Só acurácia (Fig. 10), inadequada p/ multiclasse fortemente desbalanceada; ausência de precisão/recall/F1/MCC/matriz de confusão. Confirma 0
C5 Impacto/frota	0.5	1	Impacto prático forte e QUANTIFICADO: CBM aplicado a frota real de caminhões de mineração com avaliação financeira em USD e economia de 33-57%; substituição concreta da política de horas fixas. Como Análogo, alta transferibilidade a E&C (caminhões/equipamentos pesados a diesel com ECM/chicotes). Sobe 0,5→1
C6 Reprodutib.	0	0	Sem código e sem dados públicos (proprietários de contrato de mineração/Caterpillar). Confirma 0

Total: 2.5 (Moderada) → 2.5 (Moderada).

Mudanças vs 1ª passagem: Duas alterações que se compensam (total 2,5): C1 1→0,5 (algoritmos/pré-proc. claros, mas nenhum parâmetro/hiperparâmetro) e C5 0,5→1 (impacto prático robusto e quantificado: economia 33-57%, CBM em frota real, transferível a E&C).

6. Alerta de escopo / observações

Escopo: Mineração (não E&C), coerente com Nível 2 — Análogo (frota de caminhões pesados a diesel com ECM/chicotes, tecnologia comparável a E&C).

Observações: (1) circularidade feature-alvo (alvos derivados por limiares das mesmas 2 variáveis de entrada) que compromete a validade dos >95%; (2) métrica única (acurácia) em base desbalanceada; (3) desbalanceamento não tratado; (4) ausência total de hiperparâmetros. Fortes: validação em contrato/período independentes e avaliação financeira concreta.