

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 214 · Nível 2 — Análogo · Ferroviário/Metrô · validação full-text 16/08/2026

1. Identificação

ID (master)	214
Arquivo	214-Digital_Sensor_Forecasting_for_Metro_Air_Units_A_Vector_Autoregressi.pdf
Título (EN)	Digital Sensor Forecasting for Metro Air Units: A Vector Autoregression Approach
Título (PT)	Previsão de Sensores Digitais para Unidades de Ar de Metrô: Uma Abordagem por Vetor Autorregressivo (VAR)
Autores	Sarvesh Barapatre; Shweta Tiwaskar; Omkar Gangurde; Rohit Bibwe (Vishwakarma Institute of Information Technology, Pune, Índia)
Veículo / Ano	2024 IEEE International Conference on Information Technology, Electronics and Intelligent Communication Systems (ICITEICS), 2024
DOI	10.1109/ICITEICS61368.2024.10625539
Palavras-chave	Predictive maintenance (PdM); Anomaly detection; Machine Learning; Vector Autoregression; Sensors; Metro vehicles
Datas	Conferência 28-29 jun 2024; baixado do IEEE Xplore em 21/07/2026

2. Resumo traduzido (PT)

A previsão de dados para manutenção é crucial para prevenir falhas de sistema e acidentes, identificando e classificando falhas oportunamente. Usamos o vetor autorregressivo (VAR) para prever valores de dados de sensores, útil para manutenção preditiva e detecção de anomalias. O método baseia-se nos dados de sensores digitais do conjunto MetroPT. A estrutura prevê os valores das leituras dos sensores, permitindo antecipar necessidades de manutenção e tratar falhas antes que se agravem, aumentando a confiabilidade do veículo e reduzindo o downtime da rede de metrô. Grande parte do transporte na Índia depende de ferrovias e veículos de metrô, sendo difícil verificar manualmente inúmeros pequenos componentes. Portanto, é crucial monitorar os dados dos sensores e usá-los na manutenção preditiva e na detecção de anomalias, tornando os processos operacionais mais suaves e reduzindo incidentes inesperados.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Vector Autoregression (VAR) — modelo estatístico de séries temporais multivariadas; teste ADF (Augmented Dickey-Fuller) para estacionariedade; previsão (forecasting) de sensores digitais binários aplicada a PdM/detecção de anomalias da APU
Paradigma (SQ.3)	Séries temporais (autorregressivo estatístico); os autores rotulam como 'machine learning'. Não emprega DL nem ML clássico de classificação; a etapa de detecção de anomalias (que geraria a classificação) não é implementada de forma documentada
Ferramentas	Python; biblioteca statsmodels (VAR)
Métricas (SQ.4/C4)	Precision 0,88; Recall 0,95; Accuracy 0,86; F1 0,89 (Tabela II). MAPE citada como calculada mas NÃO tabulada. Métricas de classificação — inconsistentes com o objetivo declarado de previsão/regressão
Dataset (C2)	MetroPT (Veloso et al. 2022; doi 10.1038/s41597-022-01877-3) — sensores da APU de metrô; 10.979.547 amostras. Analógicos descartados; GPS descartados; digitais usados (COMP, DV_eletric, Towers, MPG, LPS, Oil_level, Caudal_impulses; binários 0/1). Público
Validação (C3)	Split treino-teste 80-20 com integridade cronológica (split temporal, adequado a série temporal); teste separado; sem CV nem walk-forward. ADF para estacionariedade. Sem discussão explícita de vazamento além da ordem cronológica
Melhor modelo/resultado	VAR (único modelo avaliado) — F1 0,89; Recall 0,95; Precision 0,88; Accuracy 0,86. Ordem de defasagem p NÃO reportada

4. Questões secundárias (evidência)

SQ.1 Benefícios	Redução de falhas em metrô; prevenção de acidentes; menor downtime; maior eficiência/ocupação/receita; redução de custos. Todos QUALITATIVOS/prospectivos — nenhum quantificado. O único número mensurável é o desempenho do modelo (F1 0,89)
SQ.5 Código	Não há compartilhamento de código (só Python + statsmodels)

SQ.6 Dados	Dados PÚBLICOS — benchmark aberto MetroPT
SQ.7 Desafios	Série não estacionária exigindo ADF; erros no ajuste do VAR (menores principais não positivos definidos, multicolinearidade, anomalias); dificuldade de inspeção manual; climas extremos na Índia (-30°C a 50°C). (Analista): ordem p não reportada; pipeline de classificação/limiar não documentado; métricas de classificação incompatíveis com previsão
SQ.8 Lacunas/futuro	Futuro: melhorar qualidade dos dados e usar modelos mais avançados; integração em tempo real com o veículo em movimento; projetar valores futuros da APU para leituras de desgaste mais precisas

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	0.5	§III-IV: algoritmo (VAR, com notação matemática) e pré-proc. bem descritos (ADF, descarte de GPS/analógicas, nulos/outliers, timestamp, statsmodels). PORÉM faltam parâmetros-chave: a ordem de defasagem p do VAR(p) nunca é informada, e a etapa que converte previsão em rótulos de anomalia — origem das métricas — não é documentada. Rebaixado 1→0,5
C2 Dados	1	1	§III/IV: tamanho e origem exemplares — benchmark público (MetroPT) com N exato (10.979.547) e lista completa de variáveis. Confirmo 1. Ressalva: sem tratamento/justificativa de (des)balanceamento
C3 Validação	0.5	0.5	§IV: split 80-20 com 'integridade cronológica' (split temporal correto) e teste separado; ADF. Contudo, split único, sem CV temporal (walk-forward) e sem verificação explícita de vazamento. Adequado porém básico — mantém 0,5
C4 Métricas	0.5	0.5	§V/Tabela II: Precision/Recall/Accuracy/F1 — métricas de CLASSIFICAÇÃO, incompatíveis com o objetivo declarado de PREVISÃO (forecasting); MAPE (adequada p/ regressão) citada mas não tabulada; sem RMSE/MAE. Métricas existem mas não aderem à tarefa — mantém 0,5
C5 Impacto/frota	0.5	0.5	§VI (Impact) discute impacto operacional (falhas/acidentes, downtime, custos, receita), mas por ser Análogo NÃO há discussão de transferibilidade a E&C; impacto só via desempenho do modelo. Mantém 0,5
C6 Reprodutib.	0.5	0.5	Dados públicos (MetroPT), mas código NÃO compartilhado e ordem p do VAR ausente (impede replicação exata). Rubrica (código E dados) atendida só pela metade — mantém 0,5

Total: 4.0 (Moderada) → 3.5 (Moderada).

Mudanças vs 1ª passagem: C1 1→0,5 (ordem p do VAR não reportada; etapa de classificação de anomalia não documentada). C2 mantido em 1 (tamanho/origem exemplares; ausência de tratamento de desbalanceamento registrada como ressalva, mas evita dupla penalização com C1/C4). C3, C4, C5, C6 confirmados em 0,5. Total 4,0→3,5; faixa Moderada

6. Alerta de escopo / observações

Escopo: Nível 2 Análogo: frota comercial pesada (metrô/ferrovia), PdM sobre APU, IA/séries temporais (VAR). Sem contradição. Observar: domínio ferroviário/metrô e ZERO discussão de transferibilidade a E&C.

Observações: VAR é modelo estatístico — os autores o chamam de 'ML model', impreciso; (2) inconsistência central previsão(regressão) vs métricas de classificação, com o passo de rotulagem não explicado; (3) MAPE citada mas não mostrada; (4) ordem p não reportada; (5) inconsistências textuais no próprio paper. Fonte confiável de dados (MetroPT). Evidência análoga de baixo peso metodológico, útil p/ SQ7/SQ8.