

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 242 · Nível 2 — Análogo · Caminhões/comerciais · validação full-text 16/08/2026

1. Identificação

ID (master)	242
Arquivo	161-Methodology_for_Commercial_Vehicle_Mechanical_Systems_Maintenance_Data-Driven_and_Deep-Learning-Based_Prediction.pdf
Título (EN)	Methodology for Commercial Vehicle Mechanical Systems Maintenance: Data-Driven and Deep-Learning-Based Prediction
Título (PT)	Metodologia para Manutenção de Sistemas Mecânicos de Veículos Comerciais: Predição Baseada em Dados e Aprendizado Profundo
Autores	Rômulo Gonçalves Lins; Tiago Nascimento de Freitas; Ricardo Gaspar (UFABC, Santo André, Brasil)
Veículo / Ano	IEEE Access, vol. 13, 2025 (acesso aberto, CC BY), 2025
DOI	10.1109/ACCESS.2025.3543600
Palavras-chave	Commercial vehicles industry; data analysis; data-driven; deep learning; predictive maintenance of mechanical systems
Datas	Recebido 11/01/2025; aceito 12/02/2025; publicado 19/02/2025

2. Resumo traduzido (PT)

Este artigo apresenta uma estratégia de manutenção preditiva (PdM) para veículos comerciais, com foco no turbocompressor (componente crítico, porém frequentemente pouco monitorado). Ao combinar sinais de sensores, registros de manutenção de oficina e especificações técnicas, o estudo demonstra como técnicas de aprendizado profundo baseadas em dados podem identificar de forma robusta falhas iminentes. Especificamente, foram empregadas arquiteturas LSTM e LSTM Bidirecional (BiLSTM) para capturar dependências temporais e detectar padrões que abordagens convencionais e o monitoramento puramente embarcado poderiam não perceber. Resultados sobre dados reais de frota indicam que o BiLSTM alcançou maior recall (98,65%) e um cost-score menor que o LSTM padrão, destacando sua eficácia em minimizar falhas não detectadas. Embora o BiLSTM tenha gerado sobrecarga computacional ligeiramente maior, seu desempenho superior reforça o valor de integrar dados de múltiplas fontes e modelos de sequência avançados para uma PdM confiável e acionável em frotas pesadas.

3. Técnicas, dados e validação

Técnicas (SQ.2)	LSTM e BiLSTM (2 camadas LSTM 128 e 64 + BiLSTM 32 por direção; Dropout 0,3; Dense sigmoide; binary cross-entropy; Adam). Abordagem sliding-box (classificação binária, janela de 90 dias). RNN simples e CNN como baseline em testes-piloto (inferiores)
Paradigma (SQ.3)	Supervisionado (classificação binária falha/não-falha)
Ferramentas	Python (NumPy, Pandas, Matplotlib); Scikit-learn (train_test_split, MinMaxScaler); imbalanced-learn (SMOTE); Keras (Sequential API); Data Lake com Hadoop/Spark/Hive/HBase; JupyterLab em servidor Intel Xeon Gold 6152
Métricas (SQ.4/C4)	Accuracy, Precision, Recall, curva ROC, AUC (~0,993), F1-score, teste de McNemar (p<0,05), Cost-score (métrica econômica normalizada; 0,01 para BiLSTM), tempos de treino/predição
Dataset (C2)	Data Lake da indústria de veículos comerciais (dados reais). Escopo: motores Euro V >=2018, Europa e América do Sul; 2,3 milhões de observações e 100 features. Estudo do turbo: 195 veículos (95 com falha, 100 sem), 38 variáveis do ECU. Classe positiva (falha) = 16% (desbalanceado). Variáveis anonimizadas; DTCs omitidos por sigilo
Validação (C3)	Split treino/teste 80/20 estratificado + validação cruzada estratificada 5-fold; grid search de hiperparâmetros dentro da CV, seleção pelo maior AUC médio. RESSALVA: split aleatório (não temporal e aparentemente não agrupado por veículo) e SMOTE aplicado antes do split de cada fold (§IV-C) — ambos criam risco de vazamento em série temporal com múltiplas leituras por veículo
Melhor modelo/resultado	BiLSTM (recall 98,65%, F1 superior, cost-score 0,01, apenas 17 falsos negativos); LSTM teve precisão ligeiramente maior (95,72%). McNemar confirma diferença (p<0,05). Baseline RNN simples ~88%

4. Questões secundárias (evidência)

SQ.1 Benefícios	BiLSTM recall 98,65% e cost-score 0,01 (a maioria das falhas críticas detectada antes de downtime caro); AUC ~0,993; redução de falsos negativos para 17. Sem SMOTE há queda de 4-5% no recall. Qualitativos: redução de paradas, otimização de estoque, padronização da coleta, transição de manutenção por km para preditiva (menção a OEE >90% na literatura)
SQ.5 Código	Não compartilhado (bibliotecas citadas, sem repositório)
SQ.6 Dados	Não compartilhados. Dados proprietários anonimizados; DTCs omitidos. Acesso aberto CC BY cobre o texto, não os dados
SQ.7 Desafios	Ausência de sensor dedicado no turbo (cobertura parcial); grande volume de nulos (>65% removidos); forte desbalanceamento (16%); amostragem irregular (contornada por bandas de 5.000 km e forward-fill); multicolinearidade/overfitting; sobrecarga computacional do BiLSTM; resultados de um único conjunto de frota (generalização limitada)
SQ.8 Lacunas/futuro	Futuro: metodologia automatizada de aquisição/armazenamento em maior escala; pré-processamento e tuning mais avançados; explorar Transformers/variantes leves e pruning p/ reduzir custo do BiLSTM; validar em outros sistemas mecânicos. Lacuna latente: falta de split temporal/por veículo e validação multi-frota

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	§III-D/E e Tabela 1 especificam arquitetura (128/64 + BiLSTM 32×2, Dropout 0,3, Dense sigmoide, Adam, 400 épocas) e faixas de grid search; pré-proc. descrito (remoção >65% nulos, Mean Imputation, SMOTE, MinMaxScaler, sliding-box de 90 dias).
C2 Dados	1	1	Dataset com tamanho e origem claros (Data Lake industrial, Euro V >=2018, 2,3M obs/100 features; subconjunto do turbo com 195 veículos e 38 variáveis). Desbalanceamento (16%) tratado com SMOTE.
C3 Validação	1	0.5	Há CV 5-fold estratificada + teste retido 20% (positivo). Porém split aleatório, não temporal, sem agrupamento por veículo, e SMOTE antes do split de cada fold (§IV-C) — em série temporal com várias leituras por veículo gera risco concreto de vazamento, coerente com métricas quase perfeitas (AUC 0,993; recall 98,65%). Rebaixado 1→0,5
C4 Métricas	1	1	Conjunto amplo e adequado p/ PdM desbalanceada: Accuracy, Precision, Recall, ROC/AUC, F1, McNemar e Cost-score econômico, com justificativa. Confirma 1
C5 Impacto/frota	1	1	Forte impacto prático: dados reais de frota, Cost-score econômico, foco em reduzir falhas não detectadas, envolvimento de oficinas/engenheiros. Transferibilidade a E&C alta: fusão de especificações+histórico+telemetria parcial p/ componentes sem sensor dedicado (turbo) é diretamente aplicável a equipamento pesado de construção.
C6 Reprodutib.	0	0	Sem reprodutibilidade plena: dados proprietários/anonimizados, DTCs omitidos, sem repositório de código. CC BY cobre só o texto.

Total: 5.0 (Alta) → 4.5 (Alta).

Mudanças vs 1ª passagem: C3 1→0,5. O full-text revelou split aleatório (não temporal/por veículo) e SMOTE antes do split de cada fold — risco de vazamento típico em série temporal, apesar da CV 5-fold e teste retido. Total 5,0→4,5 (permanece Alta, limite inferior)

6. Alerta de escopo / observações

Escopo: Confirma PdM + frota (comerciais/caminhões pesados) + IA (LSTM/BiLSTM), coerente com Nível 2 Análogo. Domínio de aplicação é logística/transporte rodoviário, não construção/E&C diretamente; relevância se sustenta como análogo por transferibilidade (equipamento pesado, cobertura parcial de sensores).

Observações: Métricas (AUC 0,993; recall 98,65%) devem ser lidas com cautela por risco de leakage e uso de um único dataset de frota. Fortes: detalhamento metodológico exemplar e caso de fusão multi-fonte útil como referência análoga. Contraste útil p/ SQ5/SQ6 (nem código nem dados públicos, apesar de acesso aberto).