

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 246 · Nível 2 — Análogo · Mineração · validação full-text 16/08/2026

1. Identificação

ID (master)	246
Arquivo	165-Data-Driven_Condition_Monitoring_of_Mining_Mobile_Machinery_in_Non-Stationary_.pdf
Título (EN)	Data-Driven Condition Monitoring of Mining Mobile Machinery in Non-Stationary Operations Using Wireless Accelerometer Sensor Modules
Título (PT)	Monitoramento de Condição Baseado em Dados de Máquinas Móveis de Mineração em Operações Não-Estacionárias Usando Módulos de Sensores Acelerômetros Sem Fio
Autores	Pablo Aqueveque; Luciano Radrigan; Francisco Pastene; Aníbal S. Morales; Ernesto Guerra
Veículo / Ano	IEEE Access, Volume 9 (2021), 2021
DOI	10.1109/ACCESS.2021.3051583
Palavras-chave	Internet of Things; mining; non-stationary operations; data-driven; heavy machinery; condition monitoring
Datas	Recebido 18/12/2020; aceito 03/01/2021; publicado 14/01/2021

2. Resumo traduzido (PT)

Este artigo apresenta um sistema de monitoramento IoT inteligente e de fácil implantação que utiliza dispositivos de medição de vibração para avaliar em tempo real a condição de tratores de esteira (bulldozers), pás carregadeiras (power shovels) e retroescavadeiras (backhoes), em operações não-estacionárias na mineração. Segundo dados operacionais e o tipo de máquina, as taxas de falha por perda total por frota podem chegar a 30%. Técnicas de análise de vibração são comuns para monitoramento de condição e detecção precoce de falhas para gerar planos de manutenção preditiva de máquinas pesadas. Porém, essa estratégia é usada intensivamente apenas para máquinas estacionárias e/ou móveis em operações estacionárias; hoje há falta de soluções para máquinas não-estacionárias. Apresenta-se uma rede de sensores de vibração sem fio custo-efetiva com capacidades de ML orientadas a dados. Acelerações em 3 eixos foram medidas com dois sensores; amplitudes e frequências em dois espectros para melhorar a resolução temporal. Múltiplos algoritmos de ML classificam a condição segundo a norma ISO 2372 de severidade de vibração: Bom, Aceitável, Insatisfatório ou Inaceitável. Após testes de campo com tratores de esteira e retroescavadeiras de diferentes fabricantes, os algoritmos classificam a saúde com acurácia entre 85% e 95%. Além disso, o sistema permite detecção precoce de estados 'Inaceitável' entre 120 e 170 horas antes da falha crítica. Os resultados demonstram que o sistema coleta dados relevantes para gerar planos de manutenção preditiva e evitar paradas não planejadas.

3. Técnicas, dados e validação

Técnicas (SQ.2)	Naïve Bayes (com estimativa de densidade por suavização e suporte positivo — melhor); SVM; Análise Discriminante. Pipeline: limpeza (IQR p/ outliers, imputação), normalização, extração de features estatísticas (média, desvio, RMS, coef. de variação, curtose, assimetria, percentis, entropia), FFT p/ espectro, seleção via clustering, SMOTE p/ balanceamento
Paradigma (SQ.3)	Supervisionado (classificação multiclasse; rótulos manuais de especialista em 4 estados ISO 2372); há etapa de clustering na seleção de features
Ferramentas	MATLAB R2020a (Classification Learner Toolbox); hardware: IMU Bosch BMI160 e acelerômetro Rohm KX220; rede BLE + 3G/4G/LTE
Métricas (SQ.4/C4)	Acurácia (85-95%; melhor 96%); TPR/recall (94%); horizonte de previsão (até 170h antes da falha; ~50h antes do diagnóstico manual). Discute precisão/recall como adequadas p/ dados desbalanceados (Tabelas 7 e 10)
Dataset (C2)	2 retroescavadeiras JCB 3CX ECO 15FT (mesma frota), 60 dias corridos em obra de manutenção de estradas em mina no Chile; vibração 3 eixos a cada 15 min; série temporal multivariada (10 variáveis); rotulagem manual por especialista. Máquina #1 sofreu falha crítica no motor diesel (4 estados); #2 apenas Bom/Aceitável. Base pequena e desbalanceada; SMOTE aplicado
Validação (C3)	FRÁGIL: não relata CV, split treino/teste nem split temporal explícito. Modelos 'treinados e avaliados' sobre os mesmos dados; parâmetros de kernel estimados dos dados de campo e SMOTE aplicado antes da avaliação (risco de vazamento). Apenas 2 máquinas. Comparação com diagnóstico manual do especialista como referência (ground truth)

Melhor modelo/resultado	Naïve Bayes (smoothing density estimate + positive support): acurácia >96%, recall médio 94%, horizonte até 170h
--------------------------------	--

4. Questões secundárias (evidência)

SQ.1 Benefícios	Deteção precoce de 'Inaceitável' 120-170h antes da falha crítica; até 50h antes do diagnóstico manual; acurácia 85-96% e recall 94%. Contexto de custo evitado: falhas custam USD 100k-200k/máquina/dia; perda total até 30% por frota; manutenção não planejada reduz disponibilidade até 37% e vida útil até 25%. Solução custo-efetiva p/ PdM
SQ.5 Código	Não há compartilhamento de código; MATLAB proprietário, sem repositório
SQ.6 Dados	Não há compartilhamento de dados; dados de campo proprietários (mina no Chile)
SQ.7 Desafios	Operações não-estacionárias dificultam a análise de vibração tradicional; datasets pequenos; desbalanceamento (falhas raras); rotulagem manual complexa; transições de estado abruptas limitam o horizonte de previsão; restrições de energia dos sensores sem fio; ambiente severo (IP67)
SQ.8 Lacunas/futuro	Monitorar frota maior e mais diversa p/ achar nº mínimo de pontos de sensoriamento; explorar algoritmos alternativos; seleção de algoritmo/variáveis dependente do estado com base em dados em tempo real; aprofundar operações não-estacionárias

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	(§IV-VI): algoritmos nomeados (Naïve Bayes, SVM, Análise Discriminante), pré-proc. detalhado (IQR, normalização, extração/seleção de features, SMOTE) e protocolo de treino (default→kernel→suporte) com toolbox MATLAB.
C2 Dados	1	1	Origem e tamanho descritos (§VI: 2 retroescavadeiras JCB, 60 dias, mina no Chile) e desbalanceamento tratado explicitamente com SMOTE (§VI.F). Base pequena reconhecida pelos autores.
C3 Validação	1	0.5	O full-text NÃO descreve CV, split treino/teste ou split temporal; modelos avaliados sobre os mesmos dados. Kernel estimado dos dados de campo e SMOTE antes da avaliação indicam risco de vazamento; apenas 2 máquinas. Comparação com diagnóstico manual do especialista sustenta 0,5 (parcial), não 0. Rebaixado 1→0,5
C4 Métricas	0.5	1	Além de acurácia, reporta recall/TPR por classificador (Tabela 7) e horizonte de previsão (Tabela 10), com discussão explícita de que a acurácia isolada engana em dados desbalanceados (§VI.F). Adequadas e conscientes do problema. Sobe 0,5→1
C5 Impacto/frota	1	1	Alto impacto prático: deploy real em máquinas de frota, planos de PdM, custo evitado e deteção precoce. Alta transferibilidade a E&C: retroescavadeiras/terraplenagem são equipamentos típicos de construção e os autores afirmam que métodos data-driven não são específicos de domínio (§IV).
C6 Reprodutib.	0	0	Sem código público (MATLAB proprietário) e sem dados públicos (campo proprietário).

Total: 4.5 (Alta) → 4.5 (Alta).

Mudanças vs 1ª passagem: C3 1→0,5 (ausência de CV/split e risco de vazamento por SMOTE/estimação de kernel nos dados de campo, com apenas 2 máquinas). C4 0,5→1 (recall/TPR + horizonte de previsão com consciência de desbalanceamento).

6. Alerta de escopo / observações

Escopo: Mineração (Nível 2 — Análogo), mas o equipamento (retroescavadeiras JCB em terraplenagem/manutenção de estradas) é tipicamente de construção e o método é domain-agnostic; transferibilidade a E&C alta.

Observações: Forte em engenharia de hardware/IoT e no pipeline de ML; principal fragilidade é a validação (sem CV/split e risco de vazamento). Frota muito pequena (2 máquinas). IEEE Access 2021, CC BY 4.0 (texto acessível, sem repositório de código/dados).