

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 335 · Nível 2 — Análogo · Empilhadeiras · validação full-text 16/08/2026

1. Identificação

ID (master)	335
Arquivo	335-Real-Time_Detection_of_Safety-Relevant_Forklift_Operating_States_usi.pdf
Título (EN)	Real-Time Detection of Safety-Relevant Forklift Operating States using Acceleration Data with a Windowing Approach
Título (PT)	Detecção em Tempo Real de Estados Operacionais Relevantes para a Segurança de Empilhadeiras usando Dados de Aceleração com uma Abordagem de Janelamento
Autores	Leonhard Feiner; Filippou Chamoulas; Johannes Fottner (Chair of Materials Handling, Material Flow, Logistics — Technical University of Munich, Alemanha)
Veículo / Ano	2021 3rd International Conference on Electrical, Communication and Computer Engineering (ICECCME), Maurício, 2021
DOI	10.1109/ICECCME52200.2021.9590983
Palavras-chave	Machine Activity Recognition; Forklift Operation; Acceleration Data; Early Classification
Datas	Conferência ICECCME, 7-8 out 2021; baixado do IEEE Xplore (USP) em 21/07/2026

2. Resumo traduzido (PT)

Nas últimas décadas, muitos estudos foram publicados sobre reconhecimento de atividades, campo em contínua evolução. Este artigo apresenta um framework para classificar os dados de aceleração provenientes do garfo de uma empilhadeira, a fim de determinar o estado operacional atual. O objetivo é um sistema que detecte de forma confiável os estados operacionais relevantes para a segurança, reportáveis ao operador como alerta ou a um sistema de gestão de frota como base para a manutenção preditiva do garfo. Assim, o desgaste do garfo pode ser reduzido e a segurança aumentada. Para o reconhecimento de atividade, treinam-se modelos de ML sobre um conjunto de dados criado pelos autores. O algoritmo foca no processamento rápido e de baixo custo computacional; para isso, usa-se uma abordagem de janelamento baseada em tempo visando a classificação precoce (early classification). Discute-se a extração de características e determina-se o tamanho ótimo de janela. Obtém-se detecção robusta em tempo real dos estados com acurácia de até 99%. Os algoritmos e o conjunto de dados são disponibilizados no GitHub em <https://github.com/tum-fml/dofos>.

3. Técnicas, dados e validação

Técnicas (SQ.2)	ML clássico para reconhecimento de atividade/estado (Machine Activity Recognition); comparação de kNN, SVM, Árvore de Decisão (DT) e Random Forest (RF); janelamento temporal com classificação precoce; extração de features no tempo e na frequência (FFT)
Paradigma (SQ.3)	Supervisionado (classificação multiclasse; problema principal reduzido a 3 classes: colisão / arrasto / demais)
Ferramentas	Hardware: acelerômetro triaxial NXP MMA8452Q + microcontrolador ESP32 no garfo; Raspberry Pi 4 Model B para aquisição/classificação. Amostragem 413 Hz, faixa +/-8 g. Nenhum framework de ML nomeado no texto (código no GitHub)
Métricas (SQ.4/C4)	Apenas Accuracy; além disso tempo de computação por classificação (ms) como métrica de tempo real. Sem precisão, recall, F1 ou matriz de confusão quantificada
Dataset (C2)	Conjunto próprio de test drives em área de testes; padrões de 300 pontos (726,4 ms) por amostra. Tabela I — 7 estados, total 639 padrões (157 colisão do garfo no solo; 116 arrasto; 69 elevar; 55 abaixar; 61 colisão do carro no fim do mastro; 131 dirigindo; 50 parado); ao menos 50 amostras/classe. Público no GitHub (tum-fml/dofos)
Validação (C3)	Divisão 70% treino / 30% teste; validação cruzada de 10 folds sobre o treino; validação adicional com dados de aceleração desconhecidos (operação ao vivo, §V.B). Sem split temporal explícito; risco de vazamento baixo (padrões rotulados discretos), mas não formalmente tratado
Melhor modelo/resultado	Random Forest — acurácia >=98,4% (até 99,1%) em 3 estados e ~93,9% em 7 estados; tempo ~2,5-3,1 ms; estável entre combinações de features (DT 2º; kNN e SVM ruins ao vivo)

4. Questões secundárias (evidência)

SQ.1 Benefícios	Desempenho de modelo e latência: acurácia até 99% (RF), >=98,4% em 3 estados, ~93,9% em 7;
-----------------	--

	tempo real ~2,5-3,1 ms com baixo poder computacional. Operacionais (redução de desgaste do garfo, segurança via alerta, base para PdM/substituição por N eventos) descritos qualitativamente — sem quantificação de custo/disponibilidade
SQ.5 Código	Sim — código/algoritmos públicos no GitHub: https://github.com/tum-fml/dofos
SQ.6 Dados	Sim — dataset público no mesmo repositório GitHub (tum-fml/dofos)
SQ.7 Desafios	Erros entre estados muito semelhantes (oscilação após colisão vs arrasto; elevação confundida com arrasto); premissa de mundo fechado (Closed-World); detecção online robusta só parcialmente atendida; dataset pequeno; classes desbalanceadas; dependência das premissas iid e Big-and-Clean-Data
SQ.8 Lacunas/futuro	Incluir mais dados e novas classes p/ reduzir má-classificação; ampliar de 3 para 7 estados de forma robusta; usar a saída como base efetiva para PdM do garfo (substituição por acúmulo de eventos); melhorar robustez em operação real

5. Qualidade C1–C6 — 1ª passagem × full-text

Crit.	1ª passagem	Full-text	Justificativa (full-text)
C1 Método	1	1	(§IV): algoritmos nomeados (kNN, SVM, DT, RF); pré-proc. explícito (remoção de entradas inválidas; filtro de mediana móvel janela 3); features tabuladas (Tabela II — min, max, max-min, média, desvio, variância, assimetria, curtose, FFT); parâmetros de janela (300/150/50 pontos; 413 Hz; +/-8 g). Mantido 1; única lacuna são os hiperparâmetros dos modelos (k, kernel, nº de árvores), mitigada pelo código público
C2 Dados	1	0.5	Tamanho/origem bem documentados (Tabela I, 639 padrões, dados próprios, sensor no garfo). Porém há desbalanceamento evidente (157 vs 50; agravado ao fundir em 3 classes) e ele NÃO é tratado (sem reamostragem/ponderação/métrica balanceada) — avaliado só por acurácia. Rebaixado 1→0,5
C3 Validação	1	1	Validação forte (§IV.C e V.B): split 70/30 + validação cruzada de 10 folds no treino + teste com dados desconhecidos de operação ao vivo. Sem split temporal explícito, mas padrões rotulados discretos e teste em dados independentes reduzem o risco de vazamento. Mantido 1
C4 Métricas	0.5	0.5	Confirma 0,5: métrica única de acurácia (§V.A), inadequada para contexto desbalanceado e crítico de segurança; sem precisão/recall/F1 nem matriz de confusão quantificada (só qualitativa). Positivo parcial: reporta tempo de computação como métrica de tempo real
C5 Impacto/frota	0.5	0.5	Impacto prático real (protótipo em hardware, tempo real ~3 ms, integração a gestão de frota citada), porém a PdM é prospectiva (o sistema fornece a base, não a implementa/quantifica) e a transferibilidade a E&C é indireta — empilhadeira de intralogística, não frota de construção; o princípio (acelerômetro + janelamento + ML de estado para PdM por desgaste) é transponível, mas não demonstrado
C6 Reprodutib.	1	1	Reprodutibilidade plena — código E dados públicos no GitHub (tum-fml/dofos), declarados no abstract e na conclusão

Total: 5.0 (Alta) → 4.5 (Alta).

Mudanças vs 1ª passagem: C2 1→0,5. O full-text confirma tamanho/origem, mas revela desbalanceamento não tratado e avaliação só por acurácia.

6. Alerta de escopo / observações

Escopo: Registro: (i) domínio é empilhadeira de intralogística (logística interna), não frota de canteiro de E&C — coerente com Análogo, mas a ligação com E&C é por analogia, não direta; (ii) a PdM é aplicação downstream/prospectiva; a contribuição

efetiva é reconhecimento de estado/atividade (activity recognition), não um pipeline de PdM implementado (sem RUL, sem prognóstico). Usar como evidência análoga de técnica (ML clássico + sensor + janelamento), não como caso de PdM quantificado

Observações: RF como melhor modelo, tempo real em hardware de baixo custo, código+dados abertos (raro no corpus, reforça C6). Métrica única (acurácia) em cenário desbalanceado; hiperparâmetros não reportados; mundo fechado. Boa fonte p/ SQ5/SQ6 (compartilhamento) e p/ discussão de transferibilidade técnica a frotas de E&C.