

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 347 · Nível 1 — Direto · Concreto/E&C (fabricação de concreto) · validação full-text 16/08/2026

Artigo ACM #02 · Repositório ACM

1. Identificação

Arquivo	02-Empirical exploration of predictive maintenance in concrete manufacturing Harnessing machine learning.pdf
Título (EN)	Empirical exploration of predictive maintenance in concrete manufacturing: Harnessing machine learning for enhanced equipment reliability in construction project management
Título (PT)	Exploração empírica da manutenção preditiva na fabricação de concreto: aproveitando o aprendizado de máquina para maior confiabilidade dos equipamentos na gestão de projetos de construção
Autores	Odey Alshboul; Rabia Emhamed Al Mamlook; Ali Shehadeh; Tahir Munir
Veículo / Ano	Computers & Industrial Engineering, v. 190, art. 110046 (Elsevier), 2024
DOI	10.1016/j.cie.2024.110046
Palavras-chave	Machine Learning; Construction management; Predictive Maintenance; Concrete manufacturing
Datas editoriais	Recebido 22/07/2023; revisado 21/01/2024; aceito 03/03/2024; online 04/03/2024

2. Resumo traduzido (PT)

A Manutenção Preditiva (PdM) na fabricação de concreto, particularmente quando vista sob a ótica da gestão de projetos de construção, é cada vez mais reconhecida por sua relevância. O potencial da PdM para prever inadequações estruturais e planejar sistematicamente a manutenção de máquinas é essencial para fluxos de trabalho de construção sem interrupções. O foco principal desta investigação foi utilizar as capacidades de algoritmos de aprendizado de máquina (ML) para desenvolver e validar modelos preditivos sofisticados, capazes de identificar proativamente necessidades de manutenção, reduzindo paradas e falhas inesperadas em máquinas vitais ao ciclo de produção de concreto. Foram avaliados sete classificadores de ML predominantes — Regressão Logística (LR), Árvore de Decisão (DT), Redes Neurais Artificiais (ANN), Light Gradient Boosting Machine (LightGBM), Extreme Gradient Boosting (XGBoost), Categorical Boosting (CatBoost) e Random Forest (RF). A eficácia foi medida por F1-score, Acurácia, Recall e área sob a curva ROC. O CatBoost superou os demais, atingindo F1 = 0,985, acurácia = 0,984, recall = 0,983 e área ROC = 0,984. Além disso, certos indicadores (vibração média em 24 h, pressão média em 24 h, contagem de Erro3 e tensão média em 24 h) foram identificados como decisivos para prever falhas de máquinas na fabricação de concreto. Os achados reforçam a importância de incorporar ML às metodologias de gestão de projetos de construção, aumentando a precisão das previsões de manutenção e a confiabilidade dos equipamentos.

3. Veredito de escopo (aderência à string de busca)

String: ("predictive maintenance") AND ("vehicle fleets" OR "fleet management") AND ("artificial intelligence" OR "machine learning") AND ("engineering and construction sector" OR "construction industry")

Bloco da string	Atende?	Evidência
"predictive maintenance"	SIM	Tema central; PdM em todo o artigo.
"vehicle fleets" / "fleet management"	NÃO	Objeto = 66 máquinas de produção estacionárias de planta de concreto. Os termos "fleet"/"vehicle" não aparecem.
"artificial intelligence" / "machine learning"	SIM	7 modelos de ML supervisionado.
"construction industry" / E&C	SIM	"construction industry" / "construction project management".

Veredito: atende 3 dos 4 blocos; falha no bloco “frota de veículos”. Setor E&C direto, mas o objeto empírico é maquinário de planta, não frota.

Classificação: **NÍVEL 1 — DIRETO (E&C, por setor), COM RESSALVAS.**

Ressalvas documentadas:

- Objeto = maquinário de planta de concreto (produção), não frota de veículos.
- Base de dados com esquema idêntico ao dataset sintético público Microsoft Azure Predictive Maintenance (volt/rotate/pressure/vibration, error1–5, sincelast_comp_1–4); nenhuma planta de concreto real é nomeada.
- Sem reprodutibilidade (código ausente; dados “disponíveis mediante solicitação”).
- Risco de vazamento (leakage): atributos sincelast_comp_1–4 (“a máquina falhará nas próximas 24 h por falha do componente X”) são proxies muito próximos do alvo e podem inflar as métricas (~0,98).

4. Técnicas de IA analisadas

Família	Técnicas
Linear/estatístico	Regressão Logística (LR)
Baseadas em árvore	Decision Tree (DT); Random Forest (RF)
Boosting (ensemble)	CatBoost (melhor); XGBoost; LightGBM
Deep Learning (raso)	ANN/MLP — 2 camadas ocultas (16, 8), ReLU, otimizador Adam
Tarefa	Classificação binária (falha × não-falha)
Paradigma (SQ.3)	Aprendizado supervisionado
Ferramentas (SQ.2)	ML clássico + boosting dominante + DL raso (scikit-learn / bibliotecas de boosting)
Complementos	Seleção de atributos (domínio + matriz de correlação); importância de variáveis; K-fold CV (k=5 e k=10)
Melhor modelo/resultado	CatBoost — k=10 (teste): Acurácia 0,984; Recall 0,983; F1 0,985; ROC-AUC 0,984
Variáveis mais preditivas	Vibração média 24h; Pressão média 24h; Erro3-count; Tensão média 24h

5. Critérios de Inclusão/Exclusão (Etapa 04)

Critério de Inclusão	Atende?	Observação
Revisado por pares · PdM em frota de veículos · ênfase E&C	PARCIAL	Peer-reviewed SIM (Elsevier); PdM SIM; E&C SIM; frota de veículos NÃO.
Usa IA/ML/Big Data para prever falhas ou otimizar manutenção	SIM	Cumprido integralmente (7 modelos de ML).
Apresenta evidência empírica (caso/experimento/quantitativo)	SIM	Experimento quantitativo com métricas e validação cruzada.

6. Qualidade metodológica (rubrica C1–C6)

Crit.	Pergunta	Nota	Evidência (seção)
C1	Método claro? (algoritmos + pré-processamento + parâmetros)	1,0	§3.2 descreve os 7 algoritmos com equações; §3.1 detalha pré-processamento (outliers via boxplot, normalização, padronização); Tabela 2 traz todos os hiperparâmetros.
C2	Dataset: tamanho/origem? trata desbalanceamento?	0,5	10.861 registros, 66 máquinas, 22 atributos; classes 4.990 falha / 5.871 não-falha (quase balanceado,

			apesar de alegar “imbalanced”); origem vaga; esquema tipo Azure PdM.
C3	Validação? (CV / teste separado / split temporal / vazamento)	0,5	Split 80/20 + K-fold CV (5 e 10) + teste separado. SEM split temporal (atributos são janelas de 24h). Risco de vazamento via <code>sincelast_comp_1-4</code> .
C4	Métricas	1,0	Acurácia, Recall, F1, ROC-AUC (Tabela 3). Obs.: Eq. (22) do F-score escrita com “accuracy” no lugar de “precision” (erro de fórmula).
C5	Impacto prático / é E&C direto ou análogo?	0,5	Implicações práticas discutidas (§5). Não é frota; “E&C direto” apenas no enquadramento; na prática é análogo de manufatura.
C6	Reprodutibilidade (código/dados)	0,0	Sem código; dados “available on request” → não reprodutível.

Pontuação estimada: 3,5 / 6 → faixa MODERADA.

C1 e C4 são firmes; C2/C3/C5 confirmados na leitura do full-text. Achado mais forte: risco de vazamento via `sincelast_comp`.

7. Decisão de triagem

INCLUÍDO no corpus. Nível 1 (Direto, E&C por setor), com as quatro ressalvas da Seção 3 documentadas. Papel na RSL: âncora de benefícios de PdM+ML no setor de construção; contribui para MQR, SQ.1, SQ.2, SQ.3, SQ.4 e SQ.7 (desafios/limitações).