

FICHA DE QUALIDADE METODOLÓGICA (full-text) — RSL

Estudo INCLUÍDO 350 · Nível 1 — Direto · Concreto/E&C (equipamentos de concretagem) · validação full-text 16/08/2026

Artigo ACM #10 · Repositório ACM

1. Identificação

Arquivo	10-Optimising concreting equipment operations in India An artificial intelligence and reliability.pdf
Título (EN)	Optimising concreting equipment operations in India: An artificial intelligence and reliability-based approach
Título (PT)	Otimização das operações de equipamentos de concretagem na Índia: uma abordagem baseada em inteligência artificial e confiabilidade
Autores	Arka Ghosh; Jemal Abawajy (Deakin University, Austrália)
Veículo / Ano	Expert Systems With Applications, v. 271, art. 126672 (Elsevier) — Open Access CC BY, 2025
DOI	10.1016/j.eswa.2025.126672
Palavras-chave	Artificial neural network; Concreting equipment; Multivariable linear regression; Predictive maintenance; Reliability engineering
Datas editoriais	Recebido 27/03/2024; revisado 21/12/2024; aceito 23/01/2025; online 01/02/2025

2. Resumo traduzido (PT)

Este estudo aplica princípios de engenharia de confiabilidade e técnicas robustas de modelagem estatística para prever o tempo de reparo e as taxas de falha de equipamentos de concretagem. Os dados foram obtidos de 15 obras de construção distintas, abrangendo a análise de 52 equipamentos de concretagem. Parâmetros críticos que impactam a produtividade dos equipamentos de construção foram identificados e quantificados e, em seguida, formulados em uma equação matemática abrangente. Foram derivadas equações matemáticas de fácil uso, capazes de prever tanto o tempo médio até o reparo (MTTR) quanto a subsequente falha do equipamento, após rigorosos procedimentos de modelagem de dados. Um modelo generalizado altamente preciso foi criado para prever taxas de falha de três tipos distintos de equipamentos de concretagem: centrais de dosagem de concreto (batching plants), caminhões-betoneira (transit mixers) e bombas de concreto — ampliando a aplicabilidade prática e a relevância do estudo no setor da construção. Esses achados oferecem insights valiosos para profissionais da construção, permitindo aprimorar o planejamento de equipamentos, a alocação de recursos e as estratégias de manutenção preemptiva. A pesquisa contribui para preencher a lacuna no entendimento da confiabilidade de equipamentos de concretagem e introduz um modelo preditivo adaptado a tipos distintos de equipamento.

3. Veredito de escopo (aderência à string de busca)

String: ("predictive maintenance") AND ("vehicle fleets" OR "fleet management") AND ("artificial intelligence" OR "machine learning") AND ("engineering and construction sector" OR "construction industry")

Bloco da string	Atende?	Evidência
"predictive maintenance"	SIM	Palavra-chave e objetivo do estudo (prever MTTR e taxas de falha).
"vehicle fleets" / "fleet management"	PARCIAL	42 dos 52 equipamentos são caminhões-betoneira (transit mixers) e 4 são bombas de concreto — veículos. O texto cita "number of transit-mixers in the fleet". Inclui também 6 centrais de dosagem (estacionárias). Aderência a "frota" bem mais forte que o #02.
"artificial intelligence" / "machine learning"	SIM	ANN (MLP tanh/sigmoide, RBF). Ressalva: núcleo é confiabilidade + regressão linear multivariável; a ANN é comparativa e perde para a regressão em 2 de 3

		equipamentos.
"construction industry" / E&C	SIM	Dados reais de 15 obras na Índia (Apêndice 1); setor de construção.

Veredito: atende ~3,5/4 blocos. Aderência a “frota” e a “E&C” fortes (maioria dos equipamentos são veículos; dados reais de obra); a IA (ANN) está presente, mas é coadjuvante.

Classificação: NÍVEL 1 — DIRETO (E&C). O Direto mais forte até agora: dados reais de campo + frota real de caminhões-betoneira/bombas.

Ressalvas documentadas:

- IA coadjuvante: o núcleo metodológico é engenharia de confiabilidade + regressão linear multivariável (SPSS); a ANN (MLP/RBF) só vence em 1 de 3 equipamentos (bomba de concreto, $R^2=0,94$).
- Amostra de modelagem pequena (ex.: $n=26$ para a central de dosagem) com R^2 in-sample altíssimo (0,988) → risco de sobreajuste; sem validação cruzada nem split temporal.
- Mistura de veículos (caminhões-betoneira, bombas) com equipamento estacionário (centrais de dosagem).
- Sem reprodutibilidade: dados “disponíveis mediante solicitação”; ferramenta proprietária (SPSS); sem código.

4. Técnicas de IA analisadas

Família	Técnicas
Engenharia de confiabilidade	MTTR, MTBF, MTTF, TBF, TTR, TTF, ConcPdBF/ConcTdBf; algoritmo “k-out-of-n”; distribuições Weibull / normal / log-normal / exponencial
Regressão	Regressão linear multivariável (+ variantes Bagging e Boosting)
Redes neurais (ANN)	MLP (ativação tanh e sigmoide) e RBF (Radial Basis Function), com/sem covariáveis (localização, código do ativo)
Estatística de apoio	ANOVA; correlação de Pearson (seleção de variáveis)
Tarefa	Regressão/predição (MTTR e taxas de falha)
Paradigma (SQ.3)	Aprendizado supervisionado
Ferramenta (SQ.2)	SPSS v.23 (ANN + regressão)
Métricas (C4)	R^2 , MSE, RMSE, MAE, MAPE (autores desaconselham o MAPE)
Melhor modelo por equipamento	Central de dosagem: regressão linear $R^2=0,988$ · Caminhão-betoneira: regressão linear $R^2=0,931$ · Bomba de concreto: MLP (tanh) c/ fatores $R^2=0,94$
Achado central	Regressão linear supera a ANN quando as relações são lineares; ANN vence só na bomba (não-linear)

5. Critérios de Inclusão/Exclusão (Etapa 04)

Critério de Inclusão	Atende?	Observação
Revisado por pares · PdM em frota de veículos · ênfase E&C	PARCIAL	Peer-reviewed SIM (Elsevier ESWA, open access); PdM SIM; E&C SIM (dados reais); frota PARCIAL-SIM (maioria caminhões-betoneira). Mais forte que o #02.
Usa IA/ML/Big Data para prever falhas ou otimizar manutenção	SIM	ANN + regressão para prever MTTR/falhas (IA coadjuvante).
Apresenta evidência empírica (caso/experimento/quantitativo)	SIM	Dados reais de campo (15 obras, 52 equipamentos); análise quantitativa.

6. Qualidade metodológica (rubrica C1–C6)

Crit.	Pergunta	Nota	Evidência (seção)
-------	----------	------	-------------------

C1	Método claro? (algoritmos + pré-processamento + parâmetros)	1,0	§2 descreve confiabilidade + regressão + ANN; equações e coeficientes dados (Eq.3–5); seleção por correlação de Pearson/ANOVA; SPSS. (Hiperparâmetros da ANN pouco detalhados.)
C2	Dataset: tamanho/origem? trata desbalanceamento?	0,5	Origem EXCELENTE: dados reais de 15 obras na Índia (Apêndice 1 detalhado), 52 equipamentos. Porém amostra de modelagem MUITO pequena (n≈26 p/ central de dosagem). Desbalanceamento N/A (regressão).
C3	Validação? (CV / teste separado / split temporal / vazamento)	0,5	Validação estatística rigorosa (F/t-test, ANOVA, Cronbach α , Durbin-Watson, VIF, normalidade, IC95%); ANN com split treino/teste. MAS sem validação cruzada, sem split temporal e R^2 in-sample altíssimo em n pequeno → risco de sobreajuste.
C4	Métricas	1,0	R^2 , MSE, RMSE, MAE, MAPE (Tabelas 3–5). Autores recomendam RMSE em vez de MAPE.
C5	Impacto prático / é E&C direto ou análogo?	1,0	Impacto prático claro (planejamento, alocação, manutenção preemptiva). E&C DIRETO com dados reais e frota real de caminhões-betoneira/bombas.
C6	Reprodutibilidade (código/dados)	0,0	Dados “available on request”; sem código; SPSS proprietário → não reprodutível.

Pontuação estimada: 4,0 / 6 → faixa MODERADA (topo). Superior ao #02 (3,5) — pesa a favor os dados reais e a frota real; contra, o C6=0 e a amostra pequena.

7. Decisão de triagem

INCLUÍDO no corpus. Nível 1 (Direto, E&C) — o ID 350 do master (o outro concreto Direto), confirmado. Contribui para MQR, SQ.1, SQ.2, SQ.3, SQ.4 e SQ.7. Diferencial frente ao #02: dados reais de campo e frota real de veículos; fragilidade: IA coadjuvante, amostra pequena e sem reprodutibilidade.